

# Основные задачи ML

## Базовые методы

## Линейные модели

Лекция 2

Иван Горбань

# План занятия:

1. Виды моделей
  - a. Категоризация по виду модели
  - b. Категоризация по задаче
  - c. Категоризация по данным
2. Bias-Variance tradeoff и train-test
3. Методы
  - a. kNN
  - b. Наивный Байес
  - c. Линейные модели
4. Подробнее о линейных моделях
  - a. Линейная регрессия
  - b. Логистическая регрессия
  - c. Регуляризация

---

# Виды моделей

Категоризации:



---

# Виды моделей

Категоризации:



# Виды моделей

Категоризации:

- I. Область применения
  - A. Объясняющие (SL)
  - B. Предиктивные (ML)



# Виды моделей

Категоризации:

- I. Область применения
  - A. Объясняющие (SL)
  - B. Предиктивные (ML)
- II. Задача:
  - A. Обучение с учителем



# Виды моделей

Категоризации:

I. Область применения

- A. Объясняющие (SL)
- B. Предиктивные (ML)

II. Задача:

A. Обучение с учителем

a. Задача регрессии

b. Задача классификации



# Виды моделей

Категоризации:

I. Область применения

- A. Объясняющие (SL)
- B. Предиктивные (ML)

II. Задача:

- A. Обучение с учителем
  - a. Задача регрессии
  - b. Задача классификации
- B. Обучение без учителя



# Виды моделей

Категоризации:

I. Область применения

- A. Объясняющие (SL)
- B. Предиктивные (ML)

II. Задача:

- A. Обучение с учителем
  - a. Задача регрессии
  - b. Задача классификации
- B. Обучение без учителя

III. Характер данных:

- A. Cross-Section
- B. Time Series
- C. Panel



---

Предиктивные vs Объясняющие



# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → инсайты

# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → инсайты

Основная задача – понять закономерности происходящих процессов, найдя зависимости в данных.

# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → инсайты

Основная задача – понять закономерности происходящих процессов, найдя зависимости в данных.

Акцент - на статистической значимости результатов.

# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → инсайты

Основная задача – понять закономерности происходящих процессов, найдя зависимости в данных.

Акцент - на статистической значимости результатов.

Примеры: линейные модели, деревья решений, k-means кластеризация

# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → инсайты

Основная задача – понять закономерности происходящих процессов, найдя зависимости в данных.

Акцент - на статистической значимости результатов.

Примеры: линейные модели, деревья решений, k-means кластеризация

**Предиктивные** – часто black box модели → высокая точность предсказаний

# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → **инсайты**

Основная **задача** – **понять закономерности** происходящих процессов, найдя зависимости в данных.

Акцент - на статистической значимости результатов.

Примеры: линейные модели, деревья решений, k-means кластеризация

**Предиктивные** – часто **black box** модели → высокая точность предсказаний

Акцент – на точности и устойчивости предсказаний.

# Предиктивные vs Объясняющие



**Объясняющие** - легко интерпретируемые модели → **инсайты**

Основная **задача** – **понять закономерности** происходящих процессов, найдя зависимости в данных.

Акцент - на статистической значимости результатов.

Примеры: линейные модели, деревья решений, k-means кластеризация

**Предиктивные** – часто **black box** модели → высокая точность предсказаний

Акцент – на точности и устойчивости предсказаний.

Примеры: градиентный бустинг, нейронные сети, многие рекомендации.



#018

# Train-test – зачем и как правильно?

В процессе построения модели данные часто делят на две или три части:

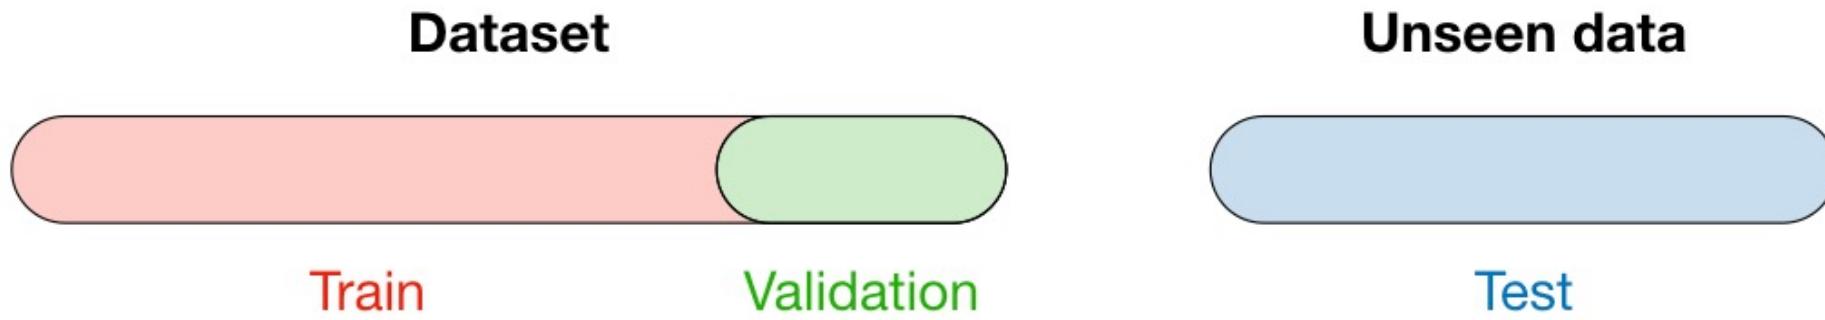
- Train
- Validation
- [Test]



# Train-test – зачем и как правильно?

В процессе построения модели данные часто делят на две или три части:

- Train
- Validation
- [Test]

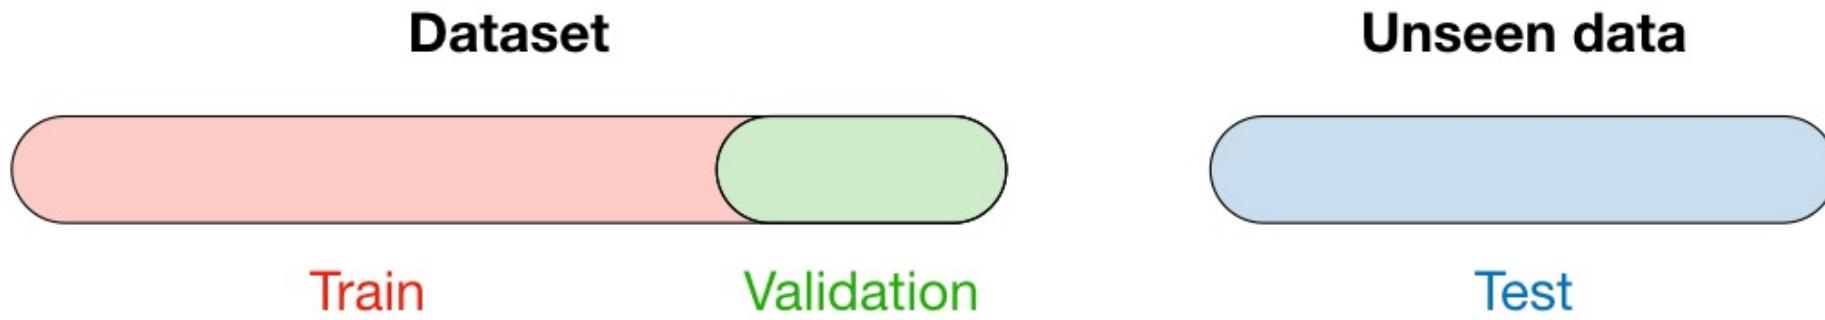


# Train-test – зачем и как правильно?



В процессе построения модели данные часто делят на две или три части:

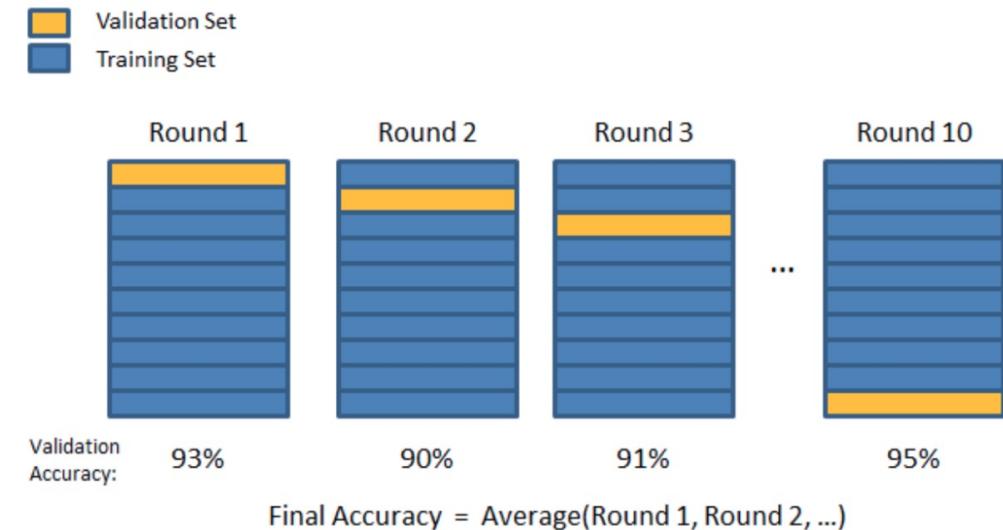
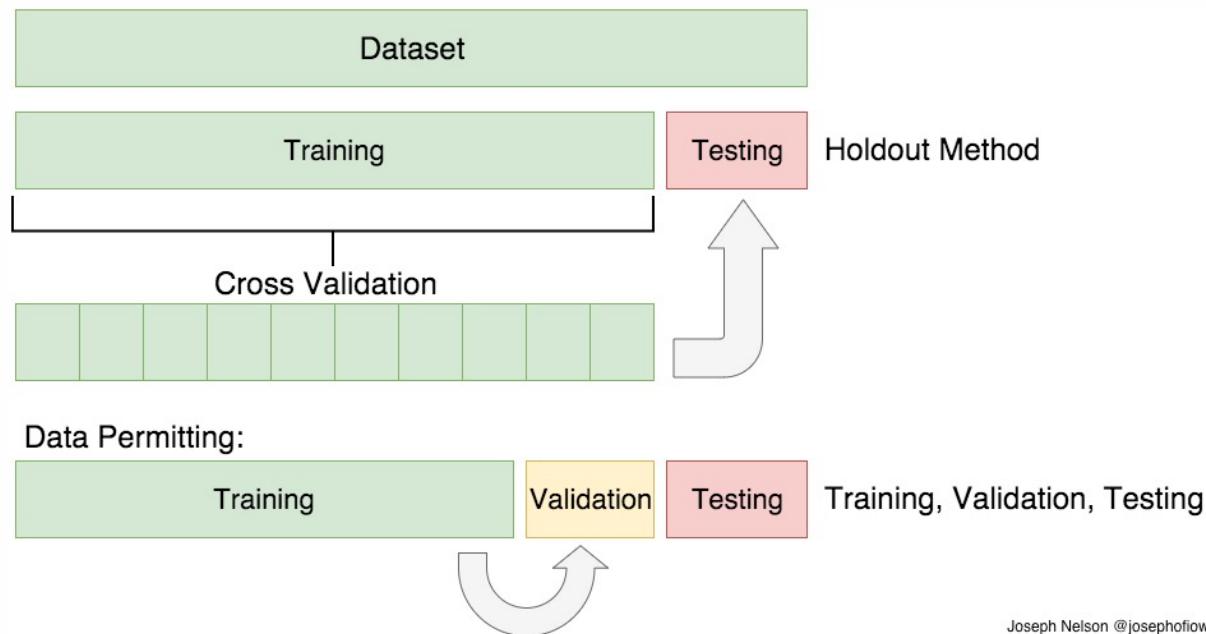
- Train
- Validation
- [Test]



Зачем?

# Train-test – зачем и как правильно?

Модификации и варианты:



Joseph Nelson @josephofiowa

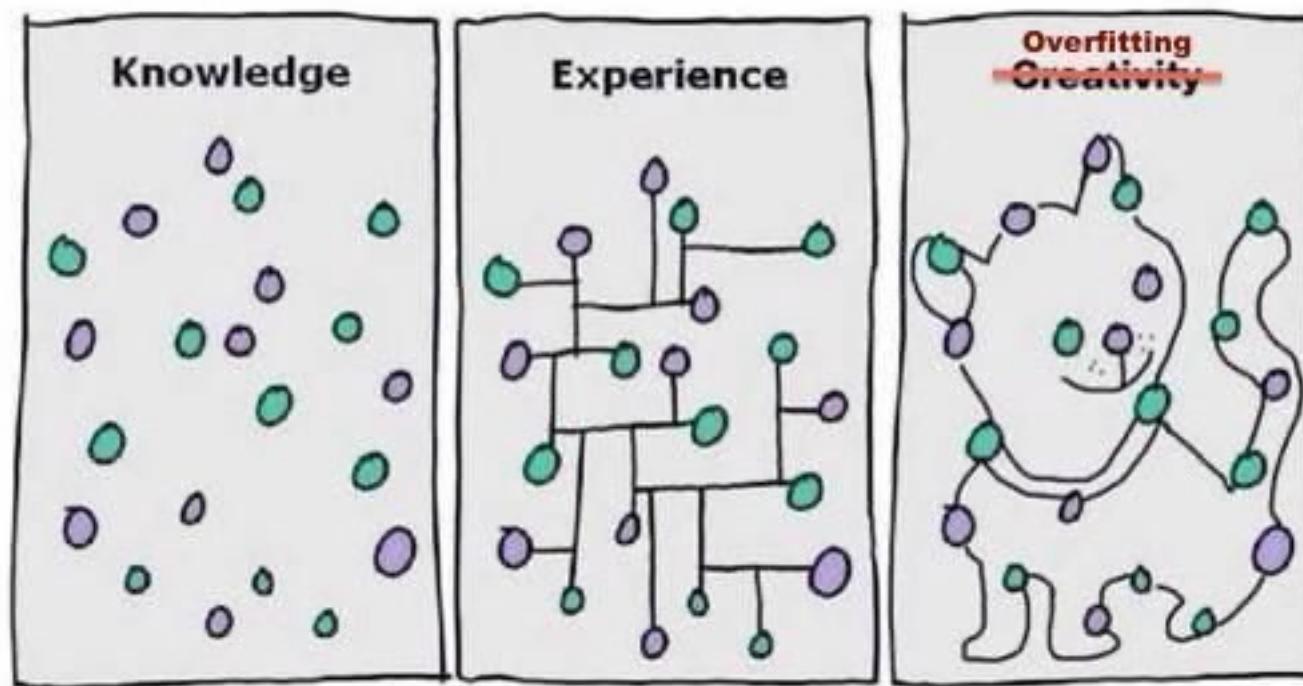
<https://towardsdatascience.com/train-test-split-and-cross-validation-in-python-80b61beca4b6>

---

Так все-таки зачем?

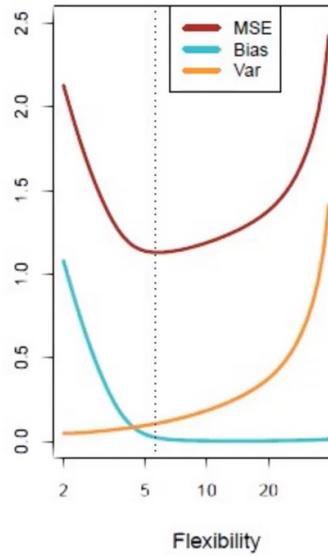
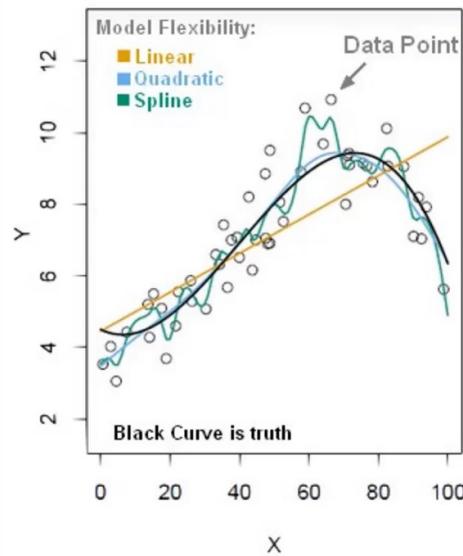
# Так все-таки зачем?

Вот зачем:



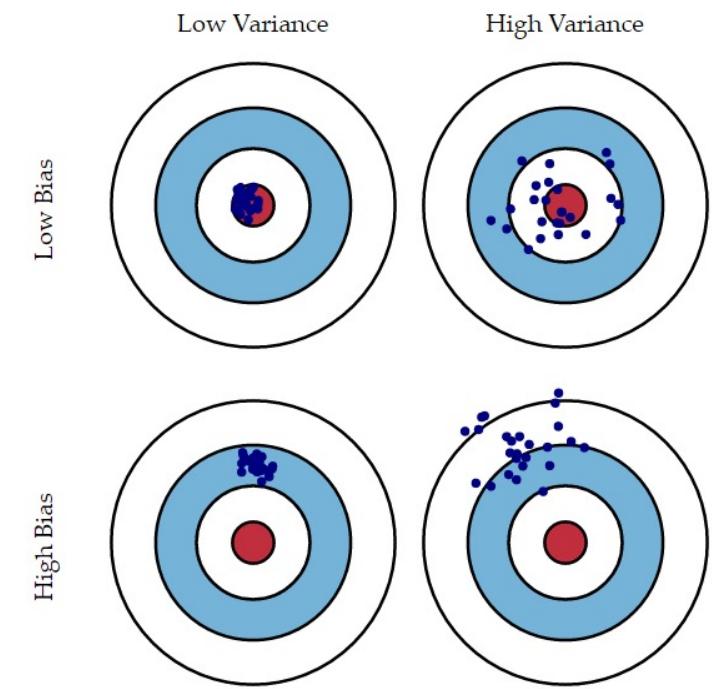
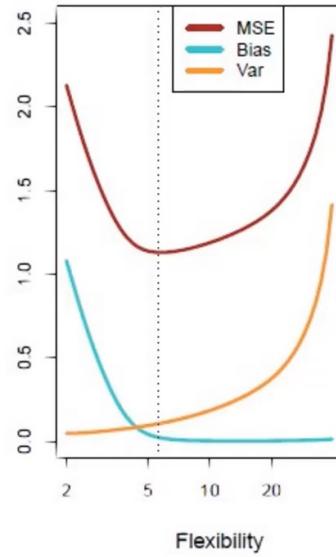
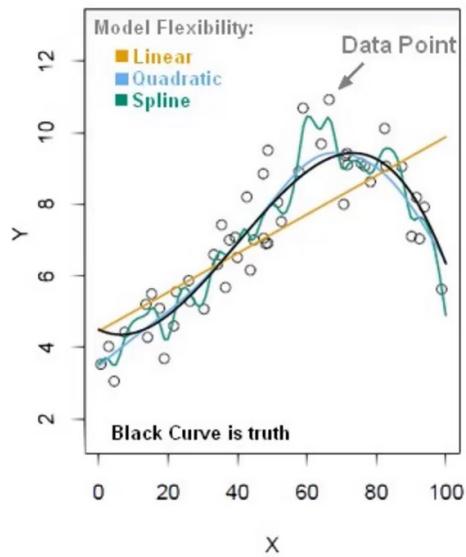
# Так все-таки зачем?

Другими словами:



# Так все-таки зачем?

Другими словами:

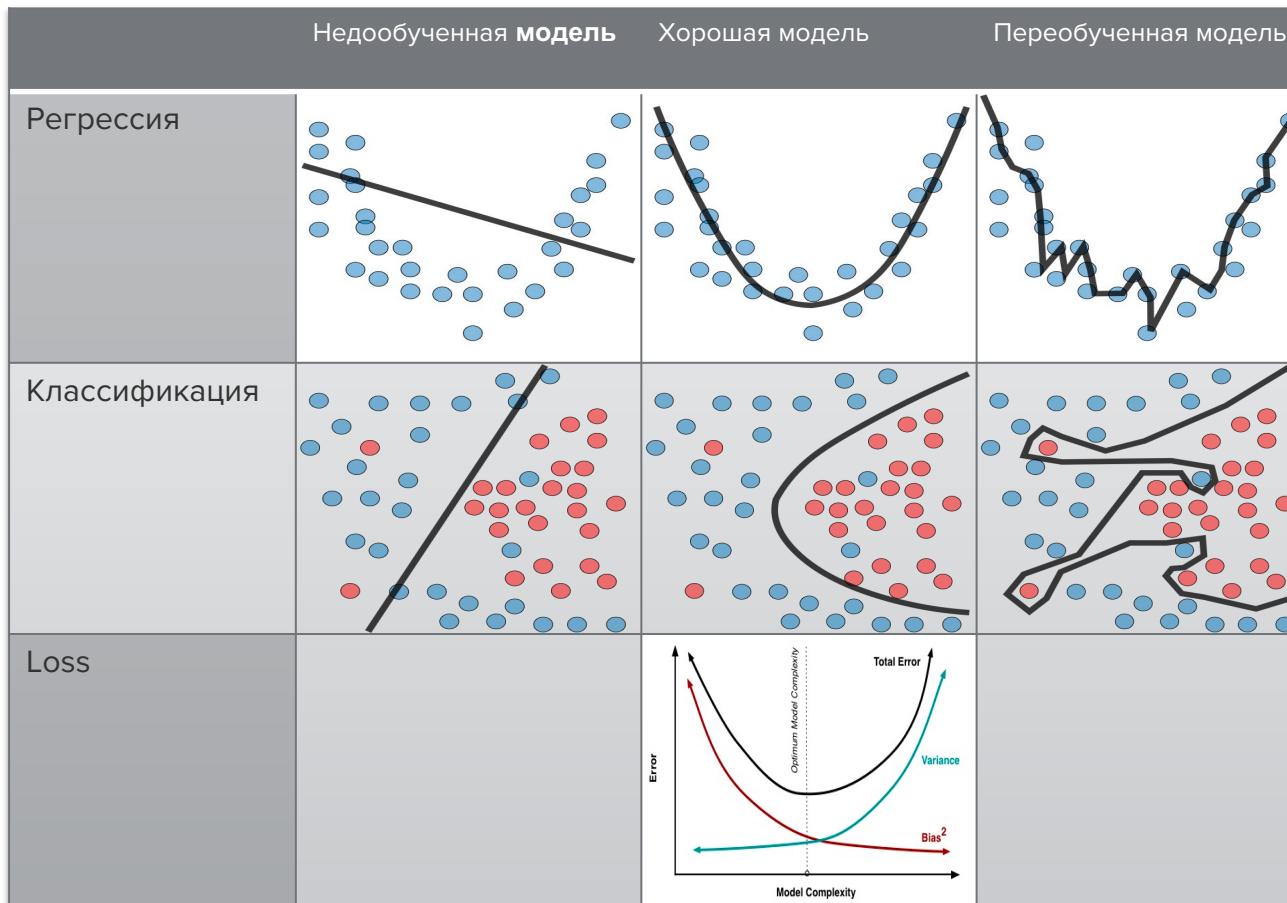


<https://www.andreaperlato.com/theorypost/bias-variance-trade-off/>

<https://medium.com/@akgone38/what-the-heck-bias-variance-tradeoff-is-fe4681c0e71b>

# Так все-таки зачем?

Еще одна иллюстрация:



---

Так все-таки зачем?

Еще одна иллюстрация:



---

Моделечки!

---

Моделечки!



Моделечки!



Эльдар?

---

Моделечки!



---

# Обучение с учителем

Machine Learning

...

---

# Обучение с учителем

- Задача регрессии

Целевая переменная  $y \in \{-\infty, \infty\}$

---

# Обучение с учителем

- Задача регрессии

Целевая переменная  $y \in \{-\infty, \infty\}$

- Задача классификации

В общем случае  $y \in \{1, 2, \dots, K\}$ , бинарная -  $y \in \{0, 1\}$

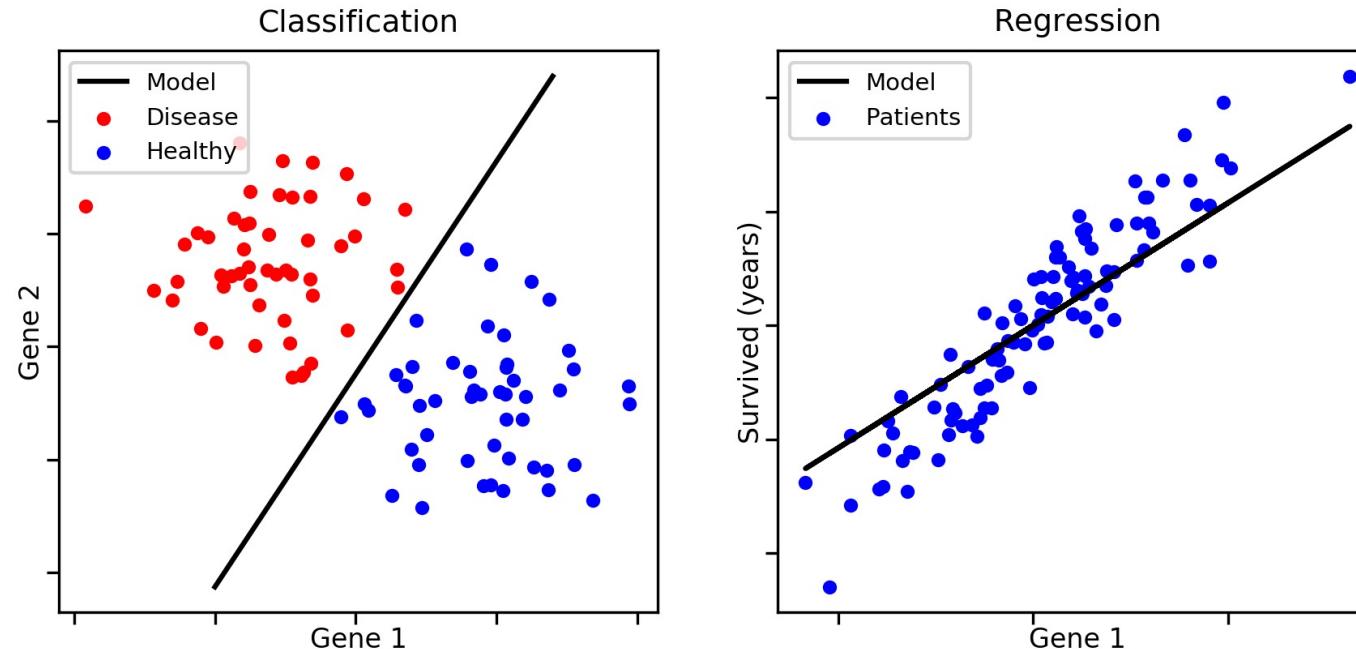
# Обучение с учителем

- Задача регрессии

Целевая переменная  $y \in \{-\infty, \infty\}$

- Задача классификации

В общем случае  $y \in \{1, 2, \dots, K\}$ , бинарная -  $y \in \{0, 1\}$



# Регрессия и классификация

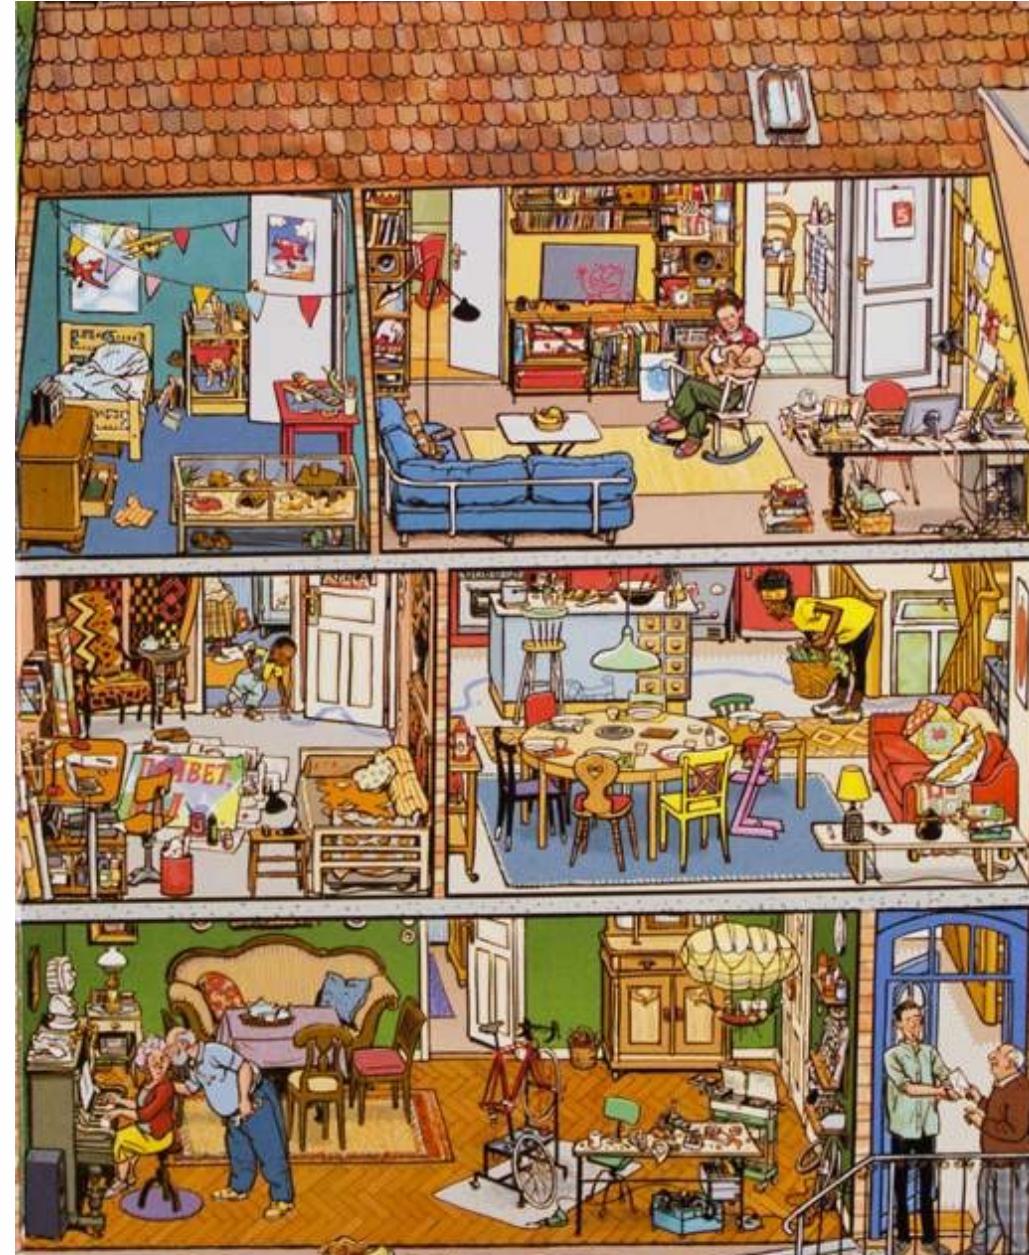
- $Y = f(X) + \epsilon$  – Общая форма для записи данных. Целевая переменная является некоторой функцией от X плюс ошибка.
- $\hat{Y} = \hat{f}(X)$  – оценка целевой переменной посредством оценки функции  $f$ .
- В задаче регрессии  $Y \in \mathbb{R}$
- В задаче классификации  $Y \in \{1, \dots, M\}$

# Задача регрессии

Признаки (Features)									Target
Train	Площадь, м <sup>2</sup>	Число комнат	Расстояние до центра, км	Новостройка	Наличие балкона	Время до метро, мин	Этаж	Высота потолков, м	Стоимость
	36	1	36	1	0	14	5	2	3 321 000
	56	2	4	0	0	3	3	4	13 000 000
	41	1	28	0	1	13	23	2.3	8 020 000
	148	4	13	1	1	7	3	5	21 412 000
	...	...	...	...	...	...	...	...	...
Test	52	3	41	1	1	53	35	2.8	?

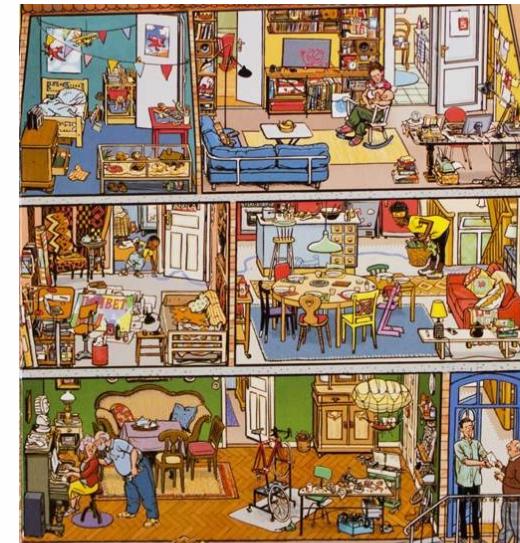
#038

#039



# Nearest Neighbors

Непараметрический метод, требующий минимальное число предположений о характере функции  $f$ .



# Nearest Neighbors

Непараметрический метод, требующий минимальное число предположений о характере функции  $f$ .

- Для регрессии:

$$\hat{Y}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i$$



# Nearest Neighbors

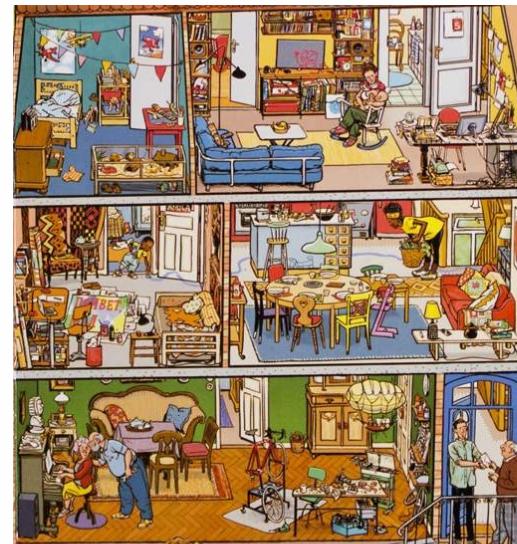
Непараметрический метод, требующий минимальное число предположений о характере функции  $f$ .

- Для регрессии:

$$\hat{Y}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i$$

- Для классификации:

$$\hat{p}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i$$



# Nearest Neighbors

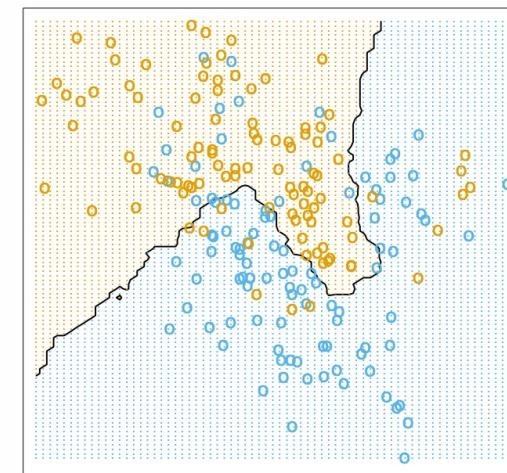
Непараметрический метод, требующий минимальное число предположений о характере функции  $f$ .

- Для регрессии:

$$\hat{Y}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i$$

- Для классификации:

$$\hat{p}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i$$



---

# Nearest Neighbors

- Какие проблемы могут возникнуть?



# Nearest Neighbors

- Какие проблемы могут возникнуть?
- Выбор k

# Nearest Neighbors

- Какие проблемы могут возникнуть?
- Выбор k
- Выбор метрики близости

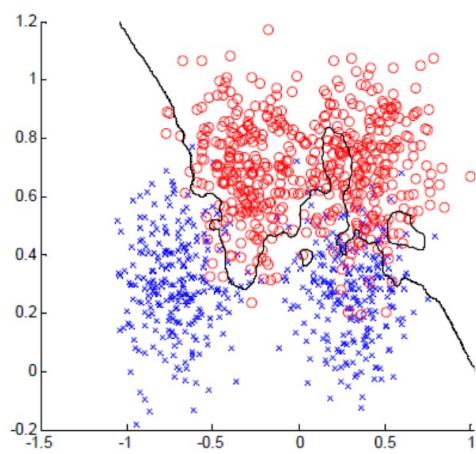
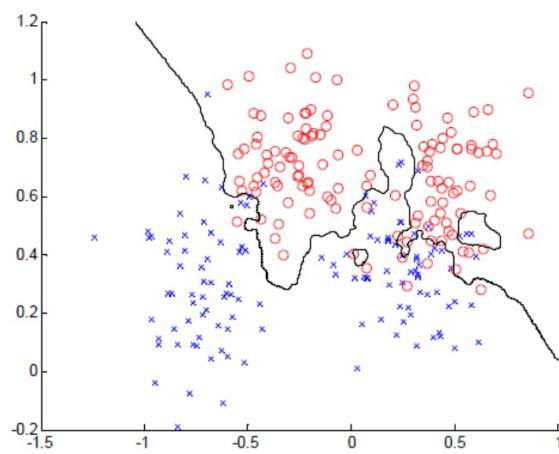
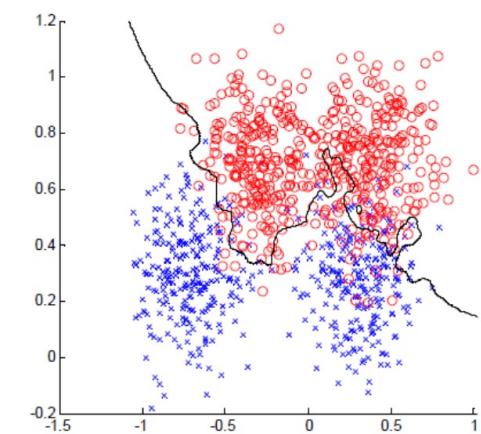
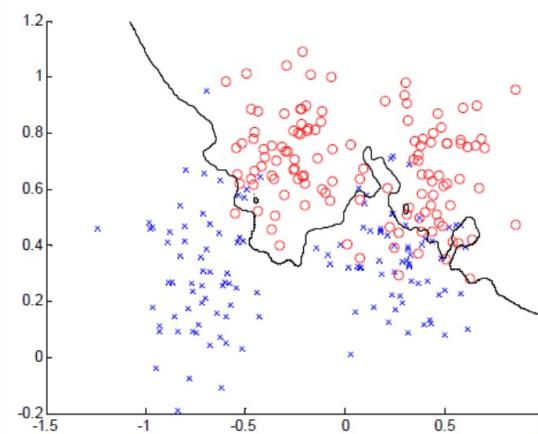
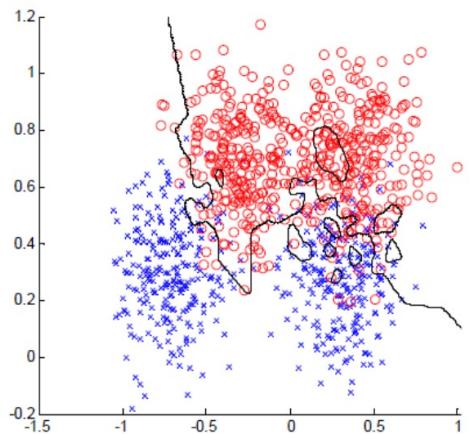
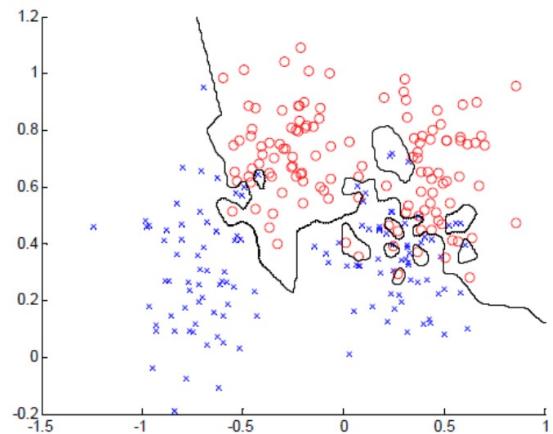
# Nearest Neighbors

- Какие проблемы могут возникнуть?
- Выбор k
- Выбор метрики близости
- Скорость вычислений

# Nearest Neighbors

- Какие проблемы могут возникнуть?
- Выбор k
- Выбор метрики близости
- Скорость вычислений
- Проклятие размерности

# Nearest Neighbors



Какие значения  $k$  в данных примерах классификации?

# Nearest Neighbors

Наиболее частым является использование **Minkowski distance** в качестве меры близости объектов:

$$\text{dist}(\mathbf{x}, \mathbf{z}) = \left( \sum_{r=1}^d |x_r - z_r|^p \right)^{1/p}$$

# Nearest Neighbors

Наиболее частым является использование **Minkowski distance** в качестве меры близости объектов:

$$\text{dist}(\mathbf{x}, \mathbf{z}) = \left( \sum_{r=1}^d |x_r - z_r|^p \right)^{1/p}$$

Как называется данная метрика:

- При  $p=1$ ?

# Nearest Neighbors

Наиболее частым является использование **Minkowski distance** в качестве меры близости объектов:

$$\text{dist}(\mathbf{x}, \mathbf{z}) = \left( \sum_{r=1}^d |x_r - z_r|^p \right)^{1/p}$$

Как называется данная метрика:

- При  $p=1$ ?
- При  $p=2$ ?

# Nearest Neighbors

Наиболее частым является использование **Minkowski distance** в качестве меры близости объектов:

$$\text{dist}(\mathbf{x}, \mathbf{z}) = \left( \sum_{r=1}^d |x_r - z_r|^p \right)^{1/p}$$

Как называется данная метрика:

- При  $p=1$ ?
- При  $p=2$ ?
- При  $p \rightarrow \infty$ ? (Пафнутий)

# Nearest Neighbors

Наиболее частым является использование **Minkowski distance** в качестве меры близости объектов:

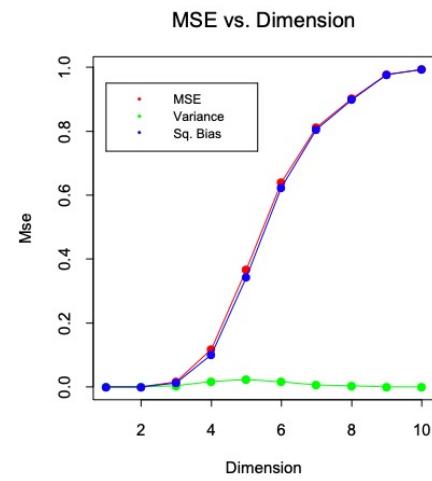
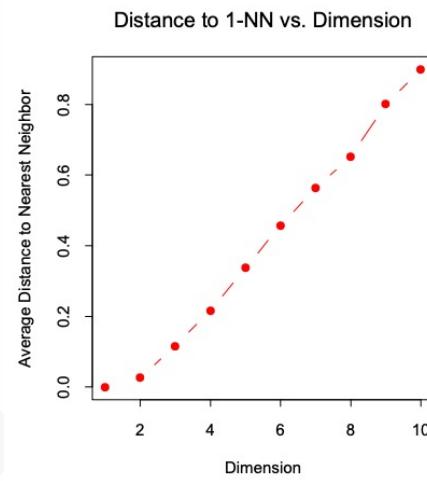
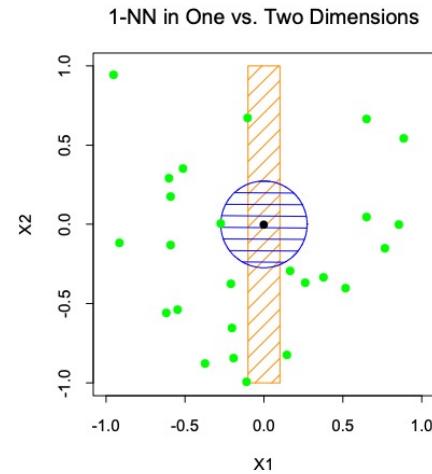
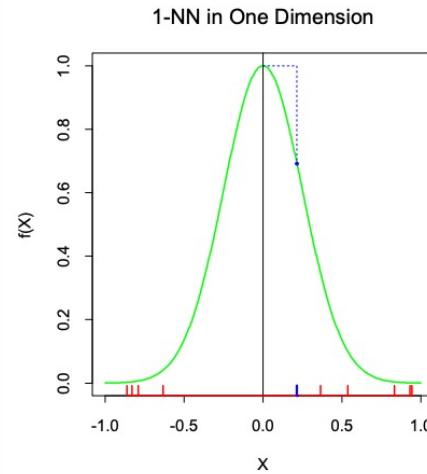
$$\text{dist}(\mathbf{x}, \mathbf{z}) = \left( \sum_{r=1}^d |x_r - z_r|^p \right)^{1/p}$$

Как называется данная метрика:

- При  $p=1$ ?
- При  $p=2$ ?
- При  $p \rightarrow \infty$ ? (Пафнутий)

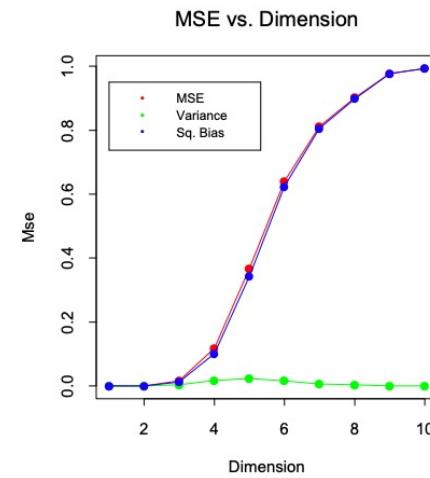
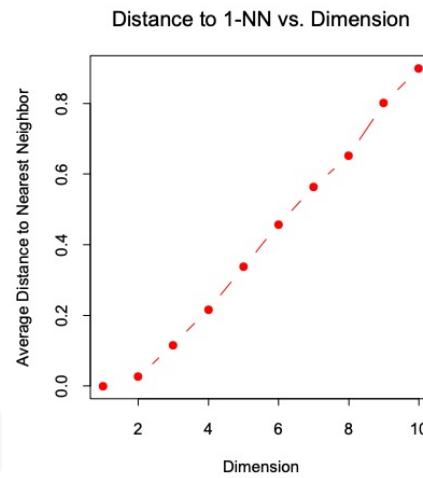
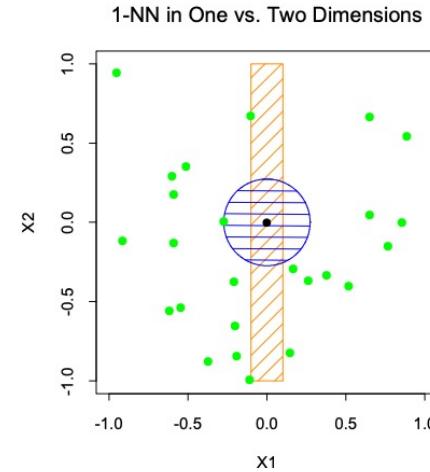
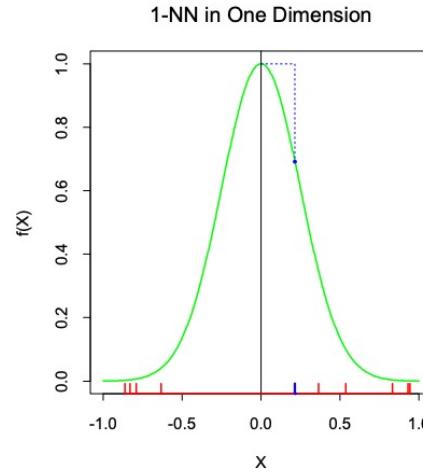
	a	b	c	d	e	f	g	h	
8	5	4	3	2	2	2	2	2	8
7	5	4	3	2	1	1	1	2	7
6	5	4	3	2	1	1	1	2	6
5	5	4	3	2	1	1	1	2	5
4	5	4	3	2	2	2	2	2	4
3	5	4	3	3	3	3	3	3	3
2	5	4	4	4	4	4	4	4	2
1	5	5	5	5	5	5	5	5	1
	a	b	c	d	e	f	g	h	

# Nearest Neighbors



В чем состоит **проклятие размерности** для kNN?

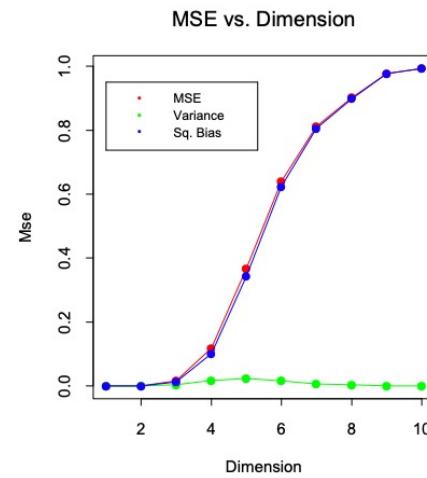
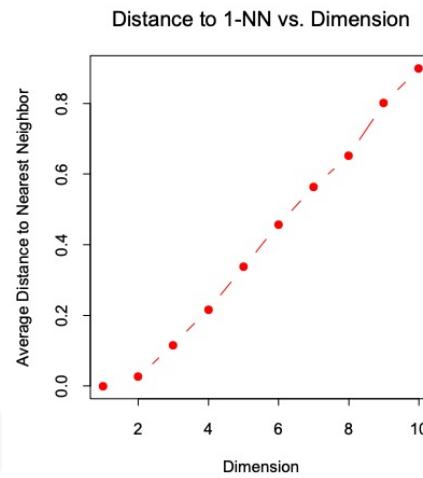
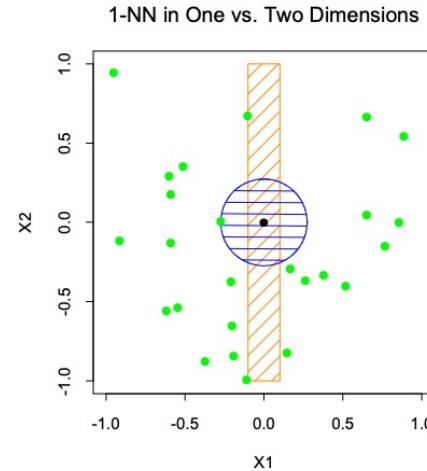
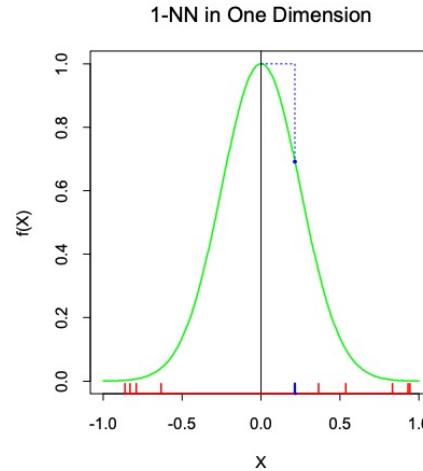
# Nearest Neighbors



В чем состоит **проклятие размерности** для kNN?

- Расстояние до ближайшего соседа растет с ростом размерности.

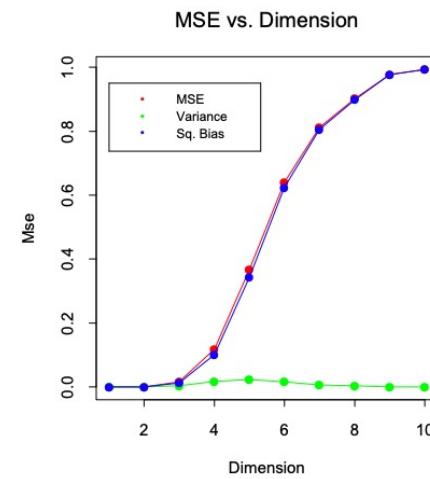
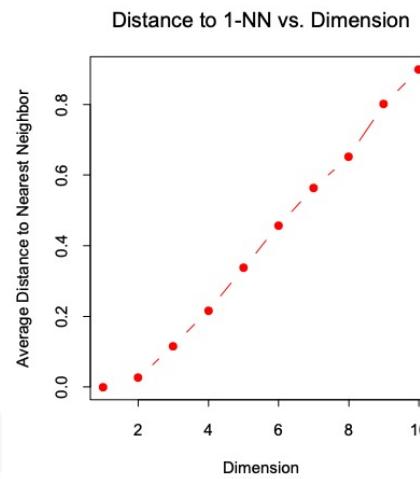
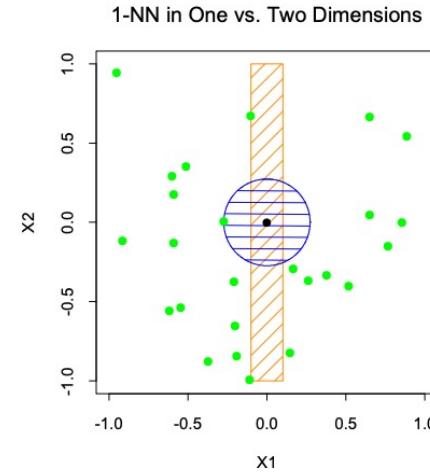
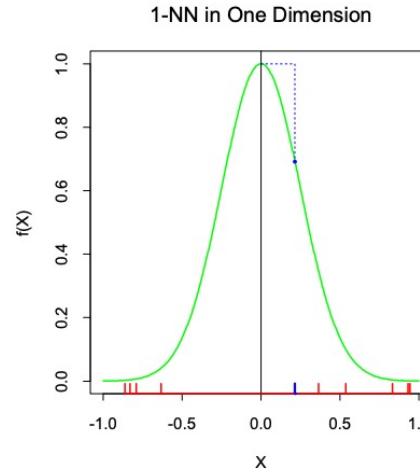
# Nearest Neighbors



В чем состоит **проклятие размерности** для kNN?

- Расстояние до ближайшего соседа растет с ростом размерности.
- По этой причине, растет bias нашей оценки.

# Nearest Neighbors



В чем состоит **проклятие размерности** для kNN?

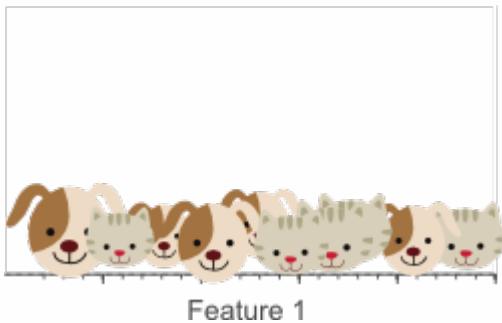
- Расстояние до ближайшего соседа растет с ростом размерности.
- По этой причине, растет bias нашей оценки.
- Более того, с ростом размерности основная масса данных при определенных допущениях распределяется по поверхности гиперсферы, что делает ближайших соседей практически неотличимыми от дальних.

# Nearest Neighbors

Проклятие размерности  $\lim_{d \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} \rightarrow 0$

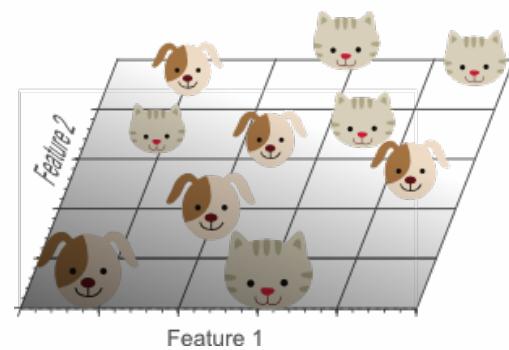
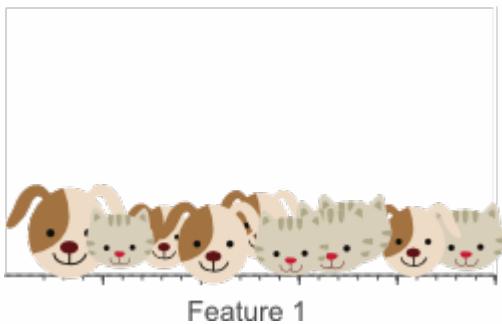
# Nearest Neighbors

Проклятие размерности  $\lim_{d \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} \rightarrow 0$



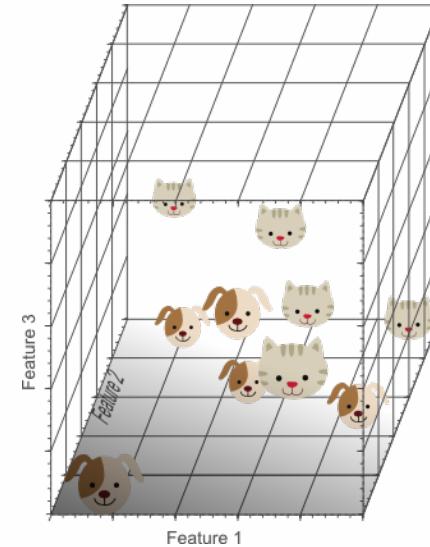
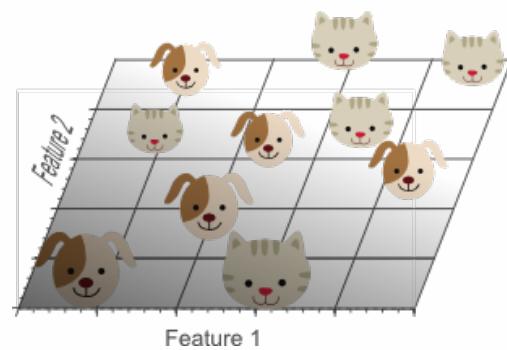
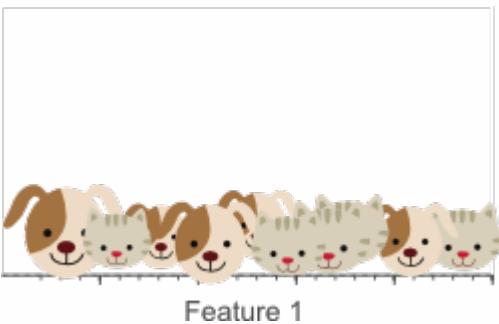
# Nearest Neighbors

Проклятие размерности  $\lim_{d \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} \rightarrow 0$



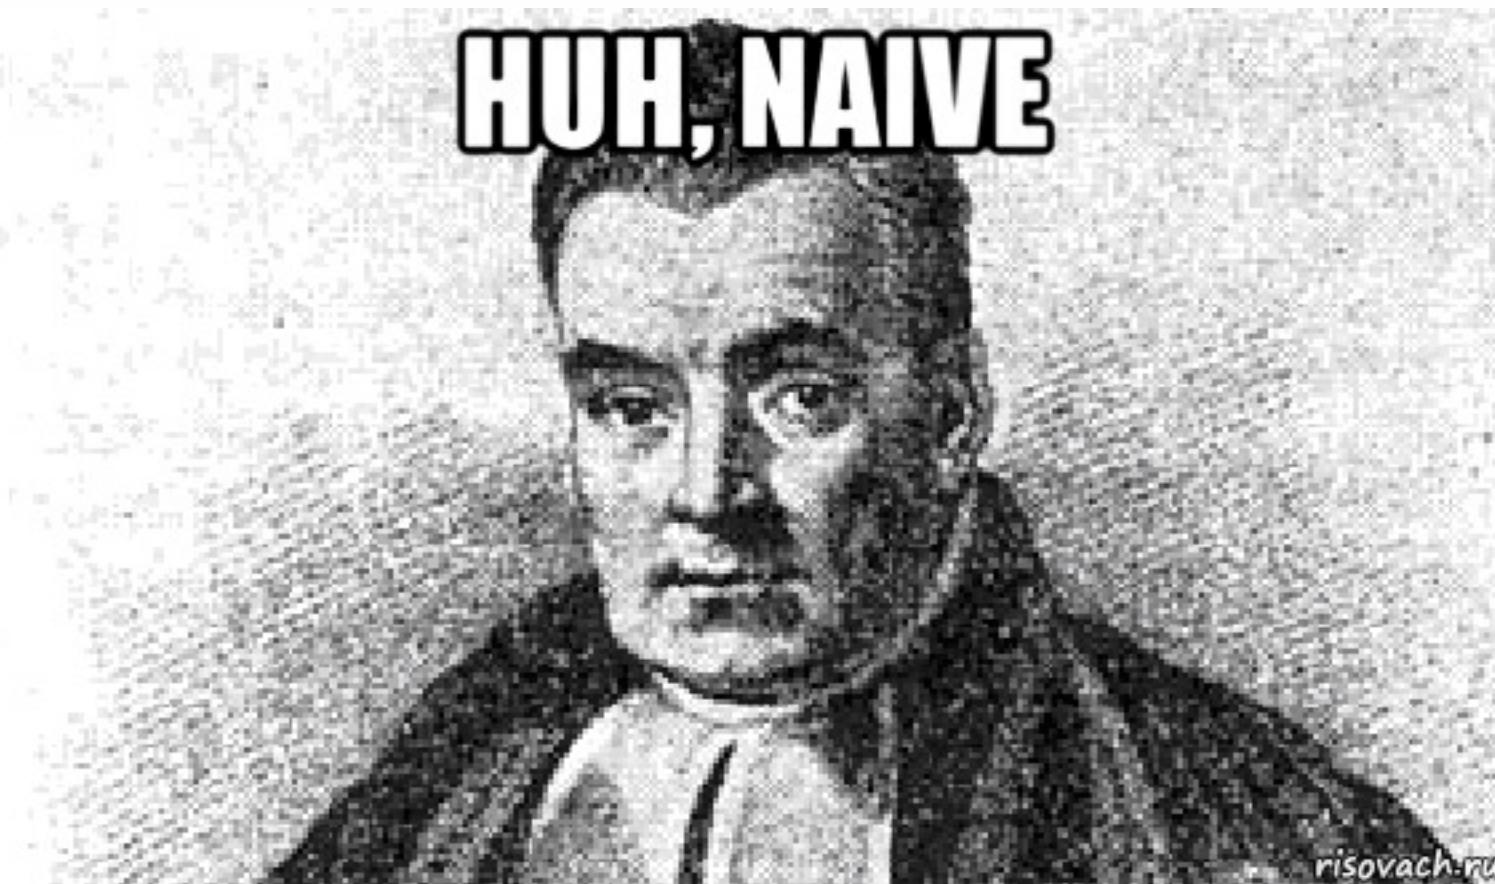
# Nearest Neighbors

Проклятие размерности  $\lim_{d \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} \rightarrow 0$



---

HUH, NAIVE



risovach.ru

#063

# Naïve Bayes

## Naïve Bayes Classifier

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$



Thomas Bayes  
1702 - 1761

#064

# Naïve Bayes

## Naïve Bayes Classifier

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$



Thomas Bayes  
1702 - 1761

Используется для классификации

- Преимущества:

- Скорость
- Малое число гиперпараметров
- Успешно работает в многомерных пространствах

# Naïve Bayes

## Naïve Bayes Classifier

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$



Thomas Bayes  
1702 - 1761

Используется для классификации

• Преимущества:

- Скорость
- Малое число гиперпараметров
- Успешно работает в многомерных пространствах

• Недостатки:

- Наивность

# Naïve Bayes

Пусть у нас бинарная классификация.

1. Предполагаем распределение наших признаков (например, нормальное).

$$P(x_i) \sim N(m_i, \sigma_i)$$

2. Используя bayes rule записываем:

$$P(y|X) = \frac{P(X|y)P(y)}{P(X)}$$

здесь  $X = \{x_1, x_2, \dots, x_m\}$

# Naïve Bayes

Главное **допущение**, которое делается далее (**наивность**) – взаимная независимость признаков. То есть:

$$P(X) = P(x_1 \cdot \dots \cdot x_m) = P(x_1) \cdot \dots \cdot P(x_m)$$

# Naïve Bayes

Главное **допущение**, которое делается далее (**наивность**) – взаимная независимость признаков. То есть:

$$P(X) = P(x_1 \cdot \dots \cdot x_m) = P(x_1) \cdot \dots \cdot P(x_m)$$

Отсюда переходим к финальной проблеме:

$$\begin{aligned}\hat{y} &= \arg \max_y \frac{P(X|y)P(y)}{P(X)} = \\ &= \arg \max_y P(X|y)P(y) = \\ &= \arg \max_y P(y) \prod_i P(x_i|y)\end{aligned}$$

# Naïve Bayes

Далее для численной стабильности желательно перейти к логарифмам:

$$\hat{y} = \arg \max_y \left\{ \ln(P(y)) + \sum_i \ln(P(x_i|y)) \right\}$$

Bottomline:

Необходимо быть внимательным к распределениям переменных!

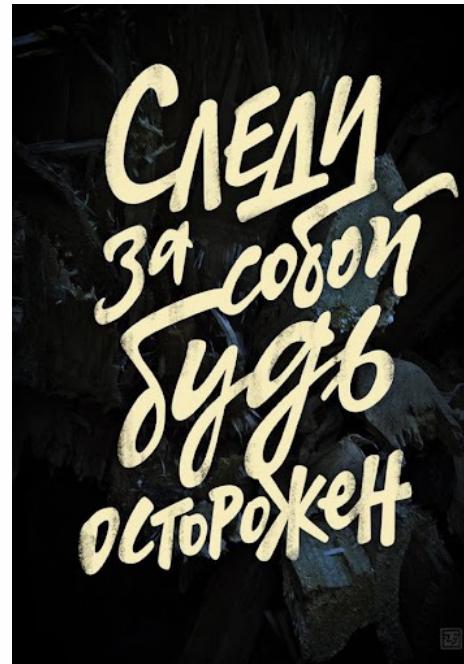
# Naïve Bayes

Далее для численной стабильности желательно перейти к логарифмам:

$$\hat{y} = \arg \max_y \left\{ \ln(P(y)) + \sum_i \ln(P(x_i|y)) \right\}$$

Bottomline:

Необходимо быть внимательным к распределениям переменных!



## Linear models. Постановка задачи

Линейная регрессия - линейная модель регрессии, которая предполагает определенную связь между зависимой и независимыми переменными, а именно:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + \epsilon_i$$

Здесь  $\epsilon_i$  - случайная величина, независимо одинаково распределенная для каждого наблюдения и отклоняющая значение игрек от линейной модели.

# Linear models. Постановка задачи

Линейная регрессия - линейная модель регрессии, которая предполагает определенную связь между зависимой и независимыми переменными, а именно:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + \epsilon_i$$

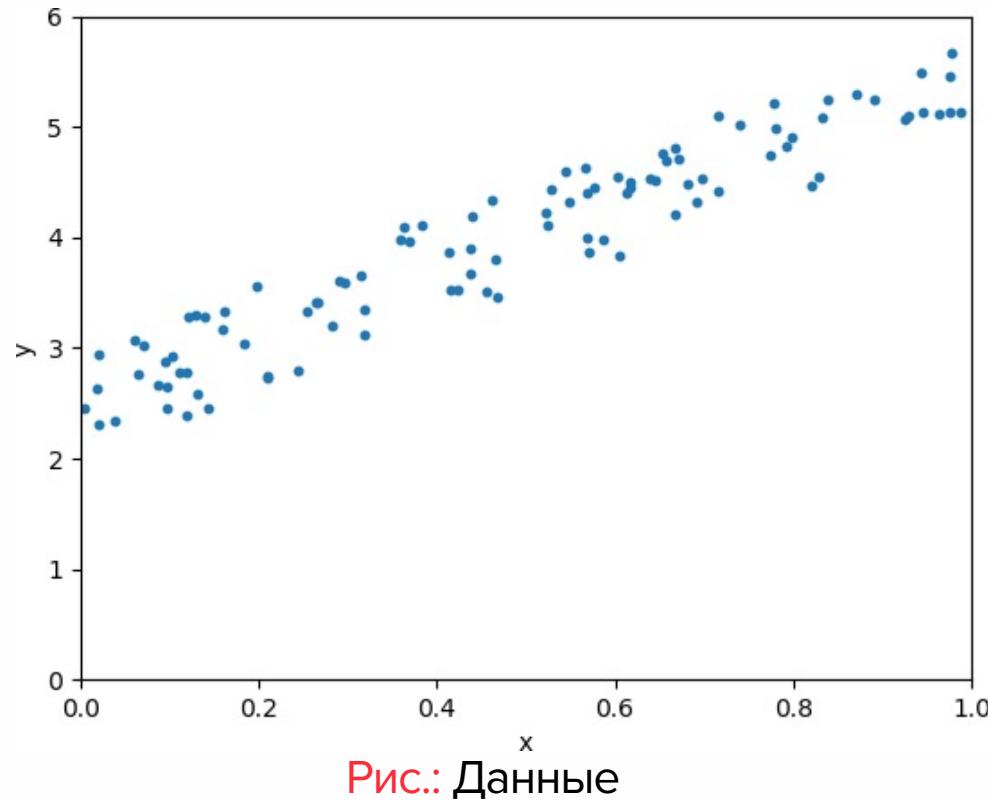
Здесь  $\epsilon_i$  - случайная величина, независимо одинаково распределенная для каждого наблюдения и отклоняющая значение игрек от линейной модели.





# Linear models. Постановка задачи

Случай двух переменных:



#074

# Linear models. Постановка задачи

Случай двух переменных:

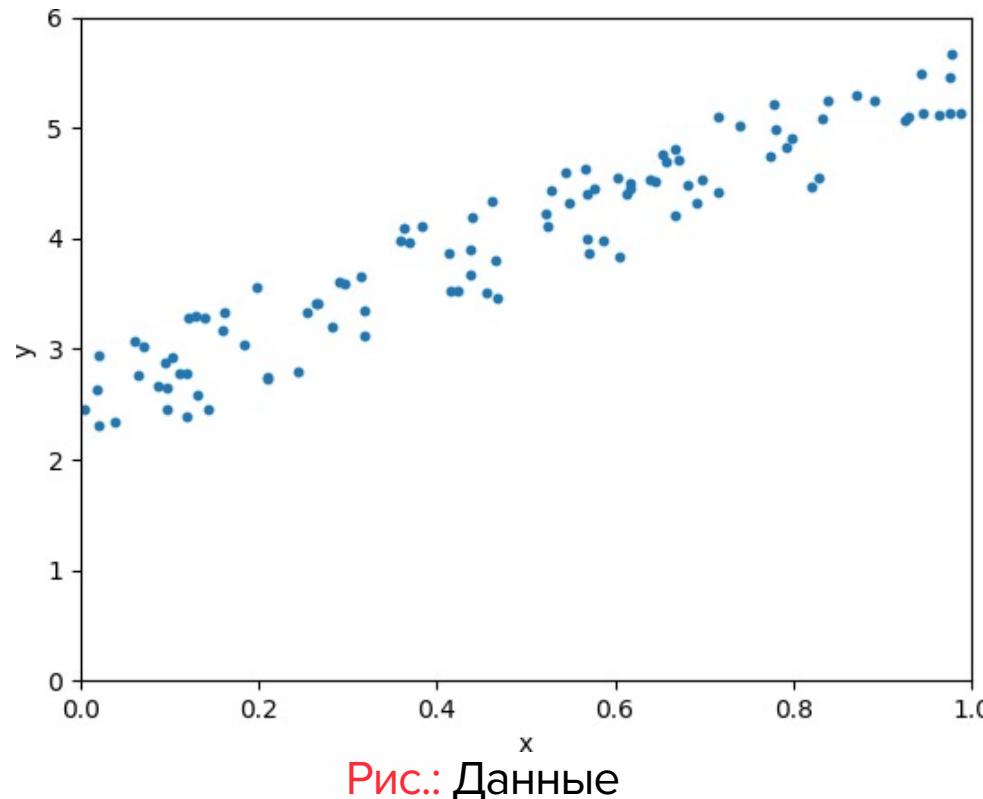


Рис.: Данные

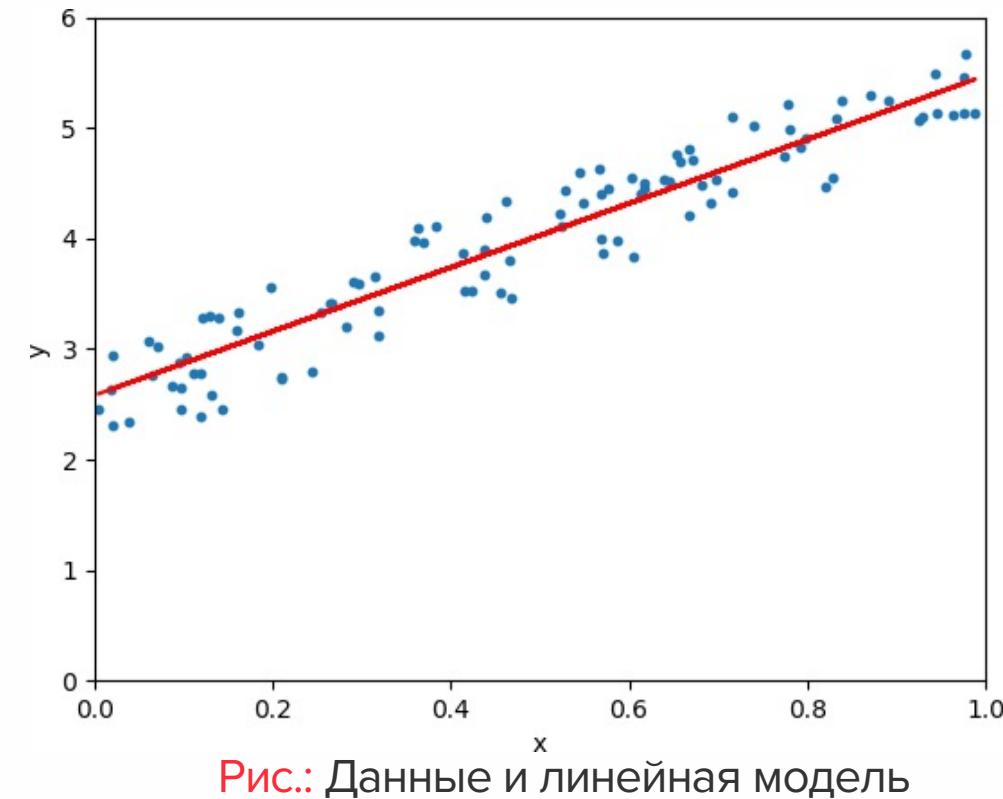


Рис.: Данные и линейная модель

# Linear models. Постановка задачи

Случай двух переменных:

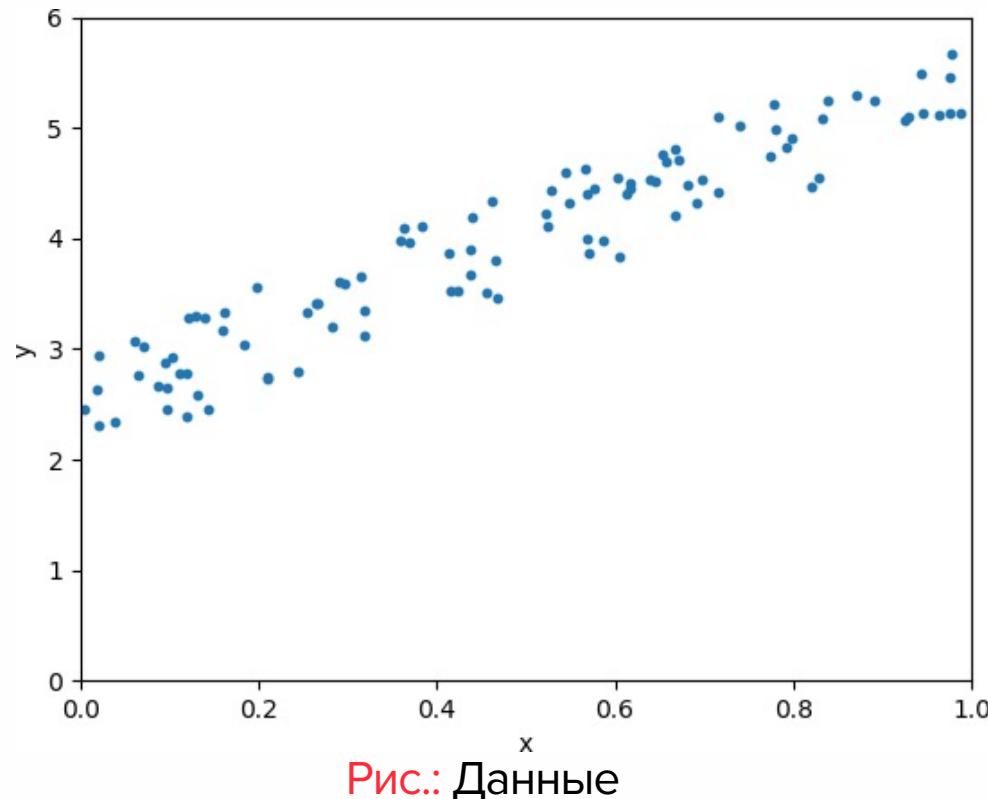


Рис.: Данные

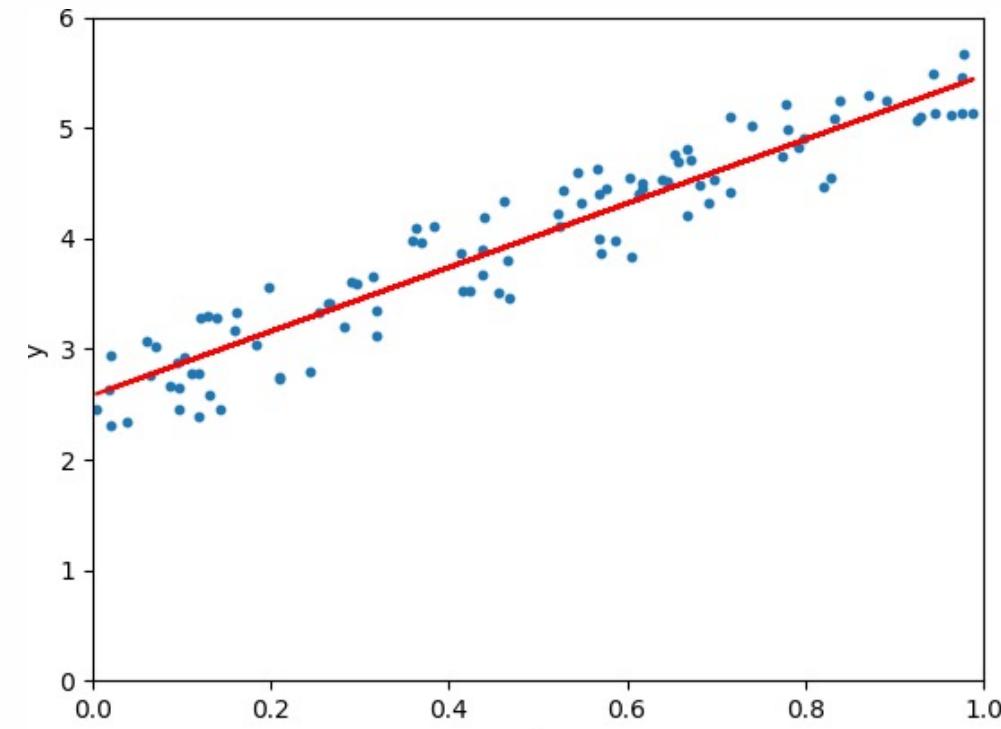


Рис.: Данные и линейная модель

#076

Линейная модель линейна по параметрам!

$$y = \beta_0 + \beta_1 x + \epsilon$$

# Linear models. Постановка задачи

- Пусть есть одна целевая переменная  $y$  и  $k$  признаков  $x_1, \dots, x_k$ .

Тогда линейная модель имеет вид:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon$$

# Linear models. Постановка задачи

- Пусть есть одна целевая переменная  $y$  и  $k$  признаков  $x_1, \dots, x_k$ .  
Тогда линейная модель имеет вид:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon$$

- Наша задача - получить оценку параметров модели  $\beta_i$   
В итоге мы хотим получить уравнение:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k$$

Главная задача, которую мы здесь решаем – восстановить зависимость таргета  $y$  от известных нам признаков  $x$ .

## Linear models. CEF.

Рассмотрим влияние различных переменных на затраты (пол, возраст и т.д.). Тогда можем рассмотреть условное матожидание при различных значениях этих параметров:

$$E(y|sex = man, age = 24, education = higher, \dots) = \dots$$

## Linear models. CEF.

Рассмотрим влияние различных переменных на затраты (пол, возраст и т.д.). Тогда можем рассмотреть условное матожидание при различных значениях этих параметров:

$$E(y|sex = man, age = 24, education = higher, \dots) = \dots$$

Для красоты:

$$E(y|x_1, x_2, \dots, x_k) = m(x_1, x_2, \dots, x_k) = m(\mathbf{x})$$

# Linear models. Prediction error.

- Введем понятие ошибки предсказания:

$$E((g(\mathbf{x}) - y)^2)$$

# Linear models. Prediction error.

- Введем понятие ошибки предсказания:

$$E((g(\mathbf{x}) - y)^2)$$

- Можно утверждать, что для любой  $g(x)$ :

$$E((g(\mathbf{x}) - y)^2) \geq E((m(x) - y)^2)$$

# Linear models. Prediction error.

- Введем понятие ошибки предсказания:

$$E((g(\mathbf{x}) - y)^2)$$

- Можно утверждать, что для любой  $g(x)$ :

$$E((g(\mathbf{x}) - y)^2) \geq E((m(x) - y)^2)$$

Таким образом,  $m(x)$  – MMSE предиктор, решающий задачу:

$$m(\mathbf{x}) = \arg \min_{g(x)} E((g(x) - y)^2)$$

## Linear models. OLS.

- Мы предположили, что данные генерируются линейной моделью:

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \epsilon_i$$

## Linear models. OLS.

- Мы предположили, что данные генерируются линейной моделью:

$$y_i = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \epsilon_i$$

- Предположим, также, что наблюдения  $(y_1, \mathbf{x}_1), \dots, (y_n, \mathbf{x}_n)$  независимы и одинаково распределены (iid). Отсюда, предполагая линейность функции  $g(\mathbf{x})$ , запишем задачу:

$$\hat{\beta} = \arg \min_{\beta} E((y - \mathbf{x}\beta)^2)$$

# Linear models. OLS.

- Имея выборку из  $n$  наблюдений, перейдем к выборочной статистике для матожидания:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n ((y_i - \mathbf{x}_i \beta)^2)$$

# Linear models. OLS.

- Имея выборку из  $n$  наблюдений, перейдем к выборочной статистике для матожидания:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n ((y_i - \mathbf{x}_i \beta)^2)$$

- Из условий минимума первого порядка (FOC) имеем:

$$\sum_{i=1}^n \mathbf{x}'_i (y_i - \mathbf{x}_i \hat{\beta}) = 0$$

# Linear models. OLS.

- Имея выборку из  $n$  наблюдений, перейдем к выборочной статистике для матожидания:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n ((y_i - \mathbf{x}_i \beta)^2)$$

- Из условий минимума первого порядка (FOC) имеем:

$$\sum_{i=1}^n \mathbf{x}'_i (y_i - \mathbf{x}_i \hat{\beta}) = 0$$

- В матричном виде модель выглядит:

$$\mathbf{y} = \mathbf{X}\beta + \epsilon$$

# Linear models. OLS.

- Имея выборку из  $n$  наблюдений, перейдем к выборочной статистике для матожидания:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n ((y_i - \mathbf{x}_i \beta)^2)$$

- Из условий минимума первого порядка (FOC) имеем:

$$\sum_{i=1}^n \mathbf{x}'_i (y_i - \mathbf{x}_i \hat{\beta}) = 0$$

- В матричном виде модель выглядит:

$$\mathbf{y} = \mathbf{X}\beta + \epsilon$$

- И FOC:

$$\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = 0$$

## Linear models. OLS.

В итоге получаем решение:

i

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{y})$$

!

# Linear models. Еще немного.

Здесь у нас MSE в качестве функции потерь:

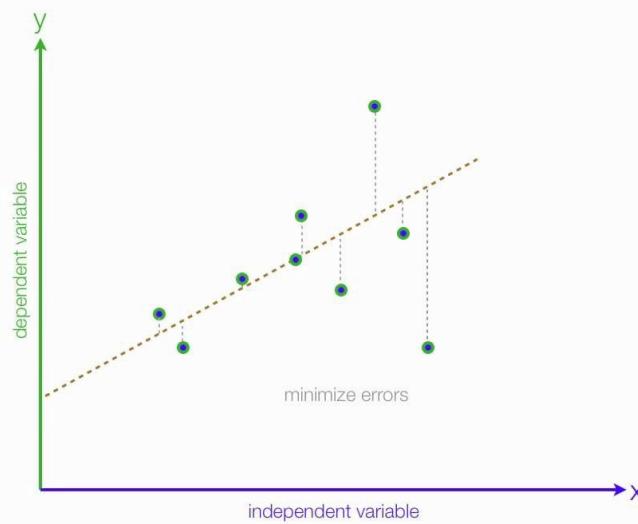
$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

# Linear models. Еще немного.

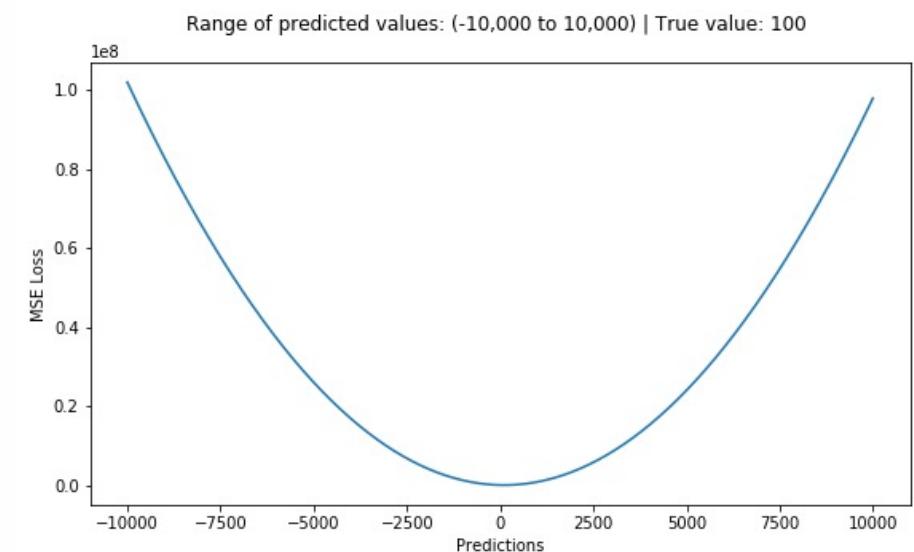
Здесь у нас MSE в качестве функции потерь:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Тогда задача и функция потерь выглядят:



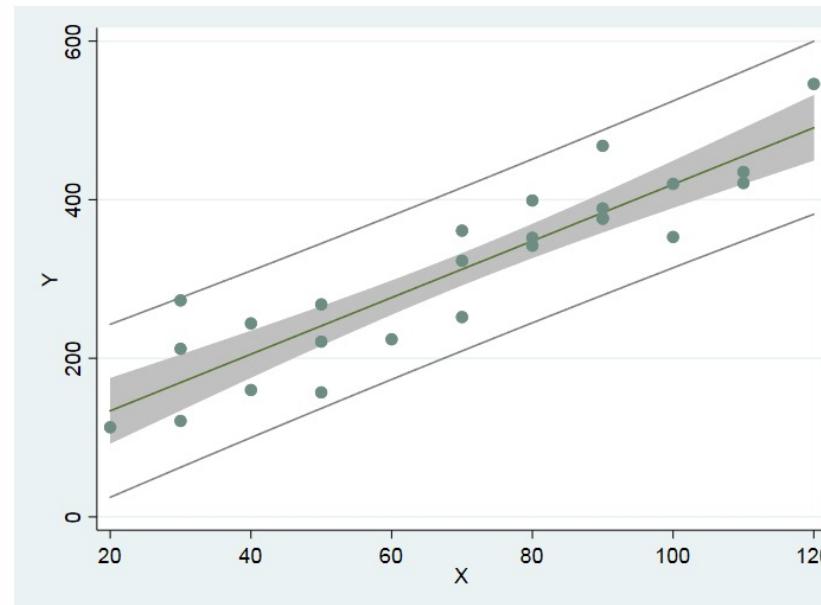
<https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared-which-metric-is-better-cd0326a5697e>



<https://heartbeat.fritz.ai/5-regression-loss-functions-all-machine-learners-should-know-4fb140e9d4b0>

# Linear models. Еще немного.

А решение будет что-то вроде этого:



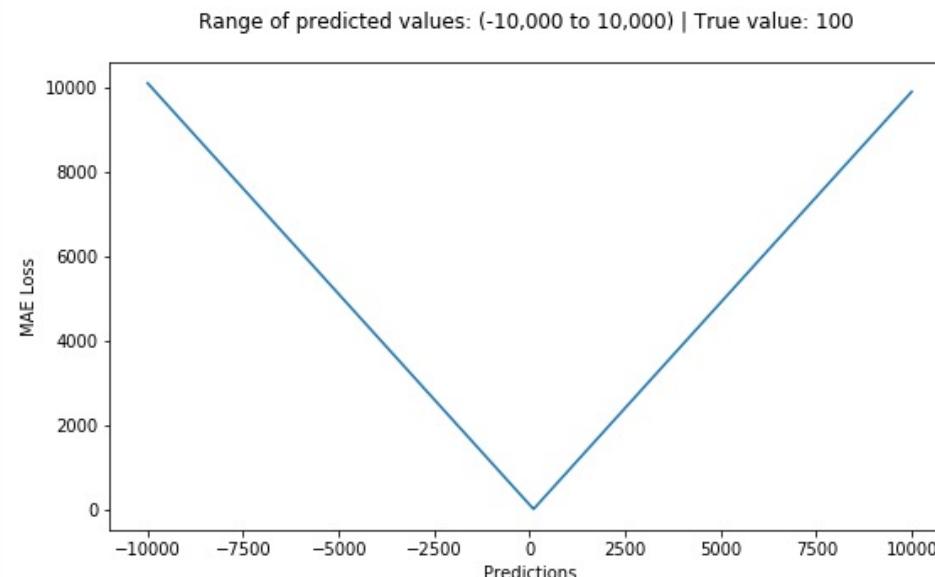
#093

# Linear models. Еще немного.

Существуют и другие функции потерь. Например:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Задача будет та же, только потери оптимизируем теперь другие:



# Linear models. Bonus slide. Assumptions OLS.

Assumption 1 (экзогенность):

$$E(\mathbf{x}'\boldsymbol{\epsilon}) = \mathbf{0}$$

Это предположение о том, что ошибка имеет нулевое среднее и некоррелирована с регрессорами.

# Linear models. Bonus slide. Assumptions OLS.

Assumption 1 (экзогенность):

$$E(\mathbf{x}'\boldsymbol{\epsilon}) = \mathbf{0}$$

Это предположение о том, что ошибка имеет нулевое среднее и некоррелирована с регрессорами.

Assumption 2 (полный ранг):

$$\text{rank}(\mathbf{x}'\mathbf{x}) = K$$

Эквивалентно предложению о положительно определенной матрице.

# Linear models. Bonus slide. Assumptions OLS.

Assumption 1 (экзогенность):

$$E(\mathbf{x}'\epsilon) = \mathbf{0}$$

Это предположение о том, что ошибка имеет нулевое среднее и некоррелирована с регрессорами.

Assumption 2 (полный ранг):

$$\text{rank}(\mathbf{x}'\mathbf{x}) = K$$

Эквивалентно предложению о положительно определенной матрице.

Теорема (состоятельность МНК):

При выполнении предложений **1** и **2** оценка  $\hat{\beta}$  является состоятельной оценкой параметра  $\beta$  из модели  $y = \beta\mathbf{x} + \epsilon$

# Linear models. Bonus slide. Assumptions OLS.

Assumption 3 (гомоскедастичность):

$$E(\epsilon^2 \mathbf{x}' \mathbf{x}) = \sigma^2 E(\mathbf{x}' \mathbf{x})$$

Где  $\sigma^2 = E(\epsilon^2)$ .

Квадрат ошибки некоррелирован с каждым элементом, их квадратами и их кросс-продуктами.

Из свойств условных матожиданий видно, что достаточным условием является  $var(\epsilon|\mathbf{x}) = \sigma^2$

# Linear models. Bonus slide. Assumptions OLS.

Assumption 3 (гомоскедастичность):

$$E(\epsilon^2 \mathbf{x}' \mathbf{x}) = \sigma^2 E(\mathbf{x}' \mathbf{x})$$

Где  $\sigma^2 = E(\epsilon^2)$ .

Квадрат ошибки некоррелирован с каждым элементом, их квадратами и их кросс-продуктами.

Из свойств условных матожиданий видно, что достаточным условием является  $var(\epsilon|\mathbf{x}) = \sigma^2$

Теорема (асимптотическая нормальность МНК):

При выполнении предположений 1, 2 и 3:

$$\sqrt{N}(\hat{\beta} - \beta) \sim \mathcal{N}(0, V_\beta)$$

$$\sqrt{N}(\hat{\beta} - \beta) \sim \mathcal{N}(0, \sigma^2 E(\mathbf{x}' \mathbf{x})^{-1})$$

# Linear models. Нормальная регрессия.

- Предположим, что **ошибка распределена нормально**. Тогда мы имеем модель:

$$\mathbf{y} = \mathbf{x}\beta + \epsilon,$$

$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

# Linear models. Нормальная регрессия.

- Предположим, что **ошибка распределена нормально**. Тогда мы имеем модель:

$$\mathbf{y} = \mathbf{x}\beta + \epsilon,$$

$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

- **Правдоподобием** называют совместную вероятность реализованвшейся выборки, рассматривая её как функцию от параметров. Для модели выше:

$$f(\mathbf{y}|\mathbf{x}) = \frac{1}{(2\pi\sigma^2)^{\frac{1}{2}}} \exp\left(-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{x}'\beta)^2\right)$$

# Linear models. ММП.

Записывая условную плотность для всей выборки, получим **функцию правдоподобия**:

$$f(y_1, \dots, y_n | \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(y_i | \mathbf{x}_i)$$

# Linear models. ММП.

Записывая условную плотность для всей выборки, получим **функцию правдоподобия**:

$$f(y_1, \dots, y_n | \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n f(y_i | \mathbf{x}_i)$$

Логарифмируя и находя максимум из FOC:

$$(\hat{\beta}_{mle}, \hat{\sigma}_{mle}^2) = \arg \max_{\beta \in \mathbb{R}, \sigma^2 > 0} \ln(L(\beta, \sigma^2))$$

# Linear models. Проверка гипотез.

OLS Regression Results						
Dep. Variable:	Calorie_Burnage	R-squared:	0.000			
Model:	OLS	Adj. R-squared:	-0.006			
Method:	Least Squares	F-statistic:	0.04975			
Date:	Tue, 29 Sep 2020	Prob (F-statistic):	0.824			
Time:	17:48:00	Log-Likelihood:	-1145.8			
No. Observations:	163	AIC:	2296.			
Df Residuals:	161	BIC:	2302.			
Df Model:	1					
Covariance Type:	nonrobust					
coef	std err	t	P> t	[0.025	0.975]	
Intercept	346.8662	160.615	2.160	0.032	29.682	664.050
Average_Pulse	0.3296	1.478	0.223	0.824	-2.588	3.247
Omnibus:	124.542	Durbin-Watson:	1.620			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	938.541			
Skew:	2.927	Prob(JB):	1.58e-204			
Kurtosis:	13.195	Cond. No.	811.			

[https://www.w3schools.com/datasience/ds\\_linear\\_regression\\_coeff.asp](https://www.w3schools.com/datasience/ds_linear_regression_coeff.asp)

# Linear models. Проверка гипотез.

Оценка коэффициента регрессии – случайная величина.

При выполнении предположений она имеет (асимптотически) нормальное распределение с математическим ожиданием равным реальному коэффициенту регрессии и некоторой дисперсией.

Смотрим на t-статистику и её p-value.

std err	t	P> t	[0.025	0.975]
160.615	2.160	0.032	29.682	664.050
1.478	0.223	0.824	-2.588	3.247

[https://www.w3schools.com/datasience/ds\\_linear\\_regression\\_pvalue.asp](https://www.w3schools.com/datasience/ds_linear_regression_pvalue.asp)

# Linear models. Проверка гипотез.

t – статистика здесь позволяет проверить гипотезу:

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

# Linear models. Проверка гипотез.

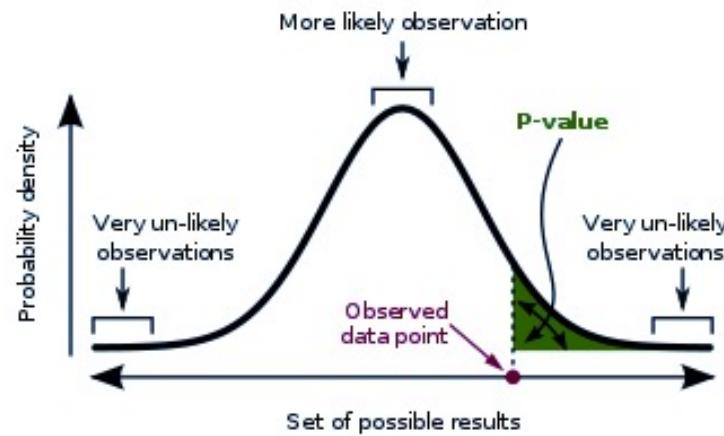
t – статистика здесь позволяет проверить гипотезу:

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

Распределение t-статистики при справедливости нулевой гипотезы:

$$t = \frac{\hat{\beta}}{se(\hat{\beta})} \sim t(n - k - 1) |_{H_0}$$



# Linear models. Проверка гипотез.

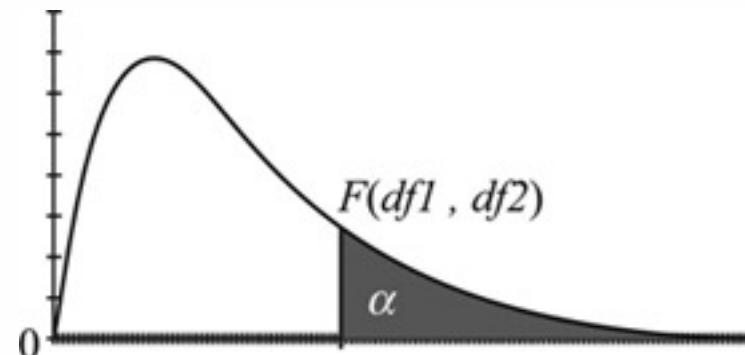
F – статистика:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$H_1 : \text{not } H_0$$

Сама F статистика выглядит следующим образом:

$$F = \frac{\left( \frac{RSS_1 - RSS_2}{p_2 - p_1} \right)}{\left( \frac{RSS_2}{n - p_2} \right)} \sim F(p_2 - p_1, n - p_2)$$



# Linear models. Градиентный спуск.

В случае, когда мы имеем дело с большими данными, иногда невозможно применить МНК (хотя существуют реализации и для этих случаев).

Применяют метод градиентного спуска. Минимизируем:

$$L(\beta) = \sum_{i=1}^n (y_i - \mathbf{x}_i \beta)^2$$

# Linear models. Градиентный спуск.

В случае, когда мы имеем дело с большими данными, иногда невозможно применить МНК (хотя существуют реализации и для этих случаев).

Применяют метод градиентного спуска. Минимизируем:

$$L(\beta) = \sum_{i=1}^n (y_i - \mathbf{x}_i \beta)^2$$

Обновляем значение:

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} - \alpha \nabla L(\hat{\beta}^{(i)})$$

# Linear models. Градиентный спуск.

В случае, когда мы имеем дело с большими данными, иногда невозможно применить МНК (хотя существуют реализации и для этих случаев).

Применяют метод градиентного спуска. Минимизируем:

$$L(\beta) = \sum_{i=1}^n (y_i - \mathbf{x}_i \beta)^2$$

Обновляем значение:

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} - \alpha \nabla L(\hat{\beta}^{(i)})$$

Останавливаемся при

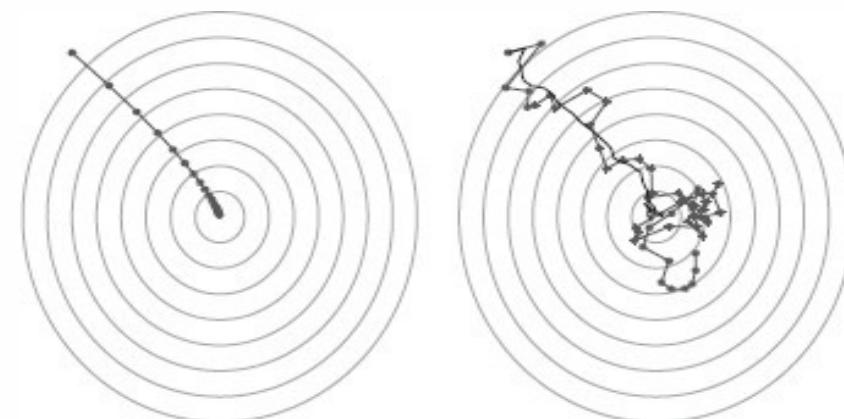
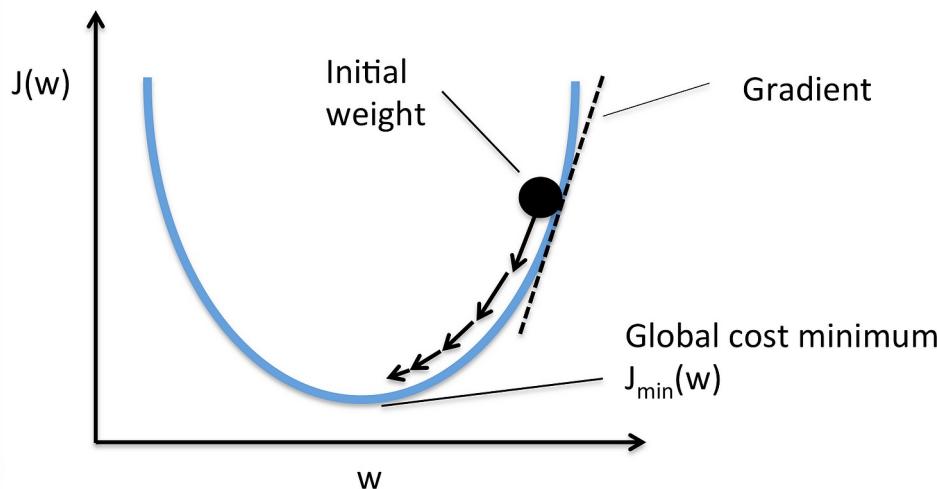
$$|\hat{\beta}^{(i+1)} - \hat{\beta}^{(i)}| < \epsilon$$

# Linear models. Стохастический градиентный спуск.

При вычислении градиента на каждой итерации суммируем значения. Долго.

Альтернатива – стохастический градиентный спуск. Считаем градиент по каждому наблюдению.

$$\hat{\beta}^{(i+1)} = \hat{\beta}^{(i)} - \alpha \nabla L_i(\hat{\beta}^{(i)})$$



# Linear models. Stepwise selection.

Отличают forward и backward stepwise selection.

Forward stepwise selection – жадный алгоритм добавления признаков.

# Linear models. Stepwise selection.

Отличают forward и backward stepwise selection.

Forward stepwise selection – жадный алгоритм добавления признаков.

Плюсы:

- Можно применять при  $k \gg n$
- Имеет меньшую дисперсию, но, возможно, большее смещение

# Linear models. Stepwise selection.

Отличают forward и backward stepwise selection.

Forward stepwise selection – жадный алгоритм добавления признаков.

Плюсы:

- Можно применять при  $k \gg n$
- Имеет меньшую дисперсию, но, возможно, большее смещение

Backward – начинается с полной модели и убирает признаки по одному.



# Linear models. Regularization.



Какие проблемы может решать регуляризация?

# Linear models. Regularization.

Какие проблемы может решать регуляризация?

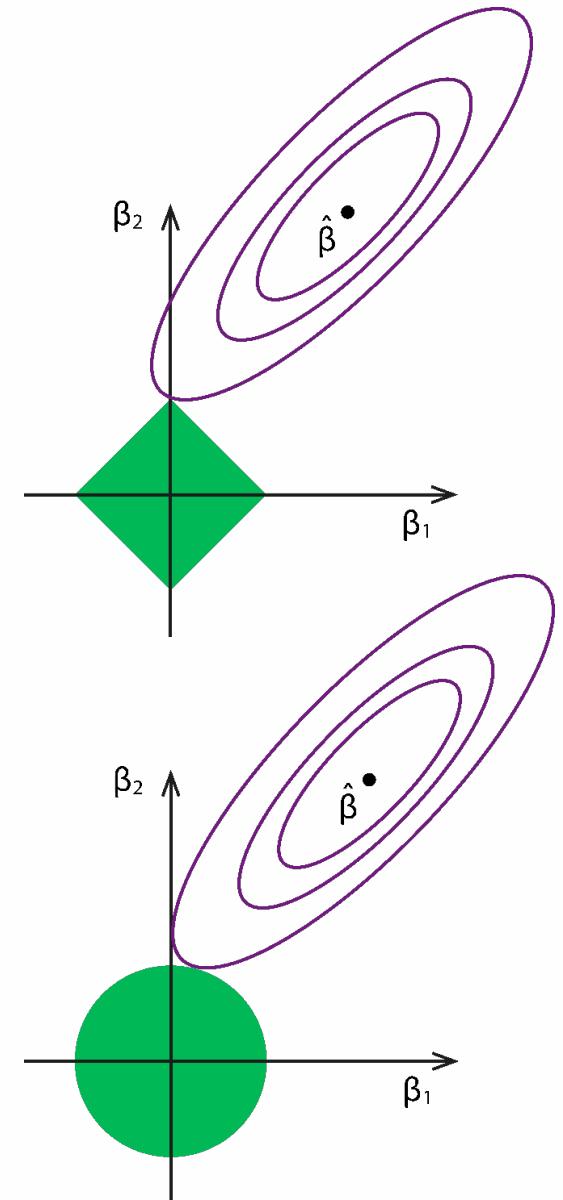
- Overfitting
- Feature selection
- High variance

# Linear models. Regularization.

Какие проблемы может решать регуляризация?

- Overfitting
- Feature selection
- High variance

Популярны два основных типа регуляризации – Ridge(L2) и Lasso(L1).



---

# Linear models. Classification.

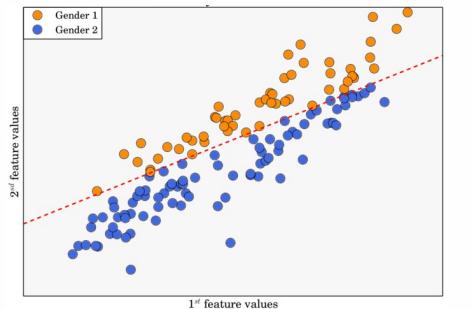
Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками

# Linear models. Classification.

Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками

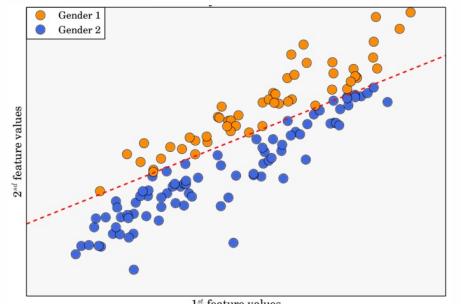


[https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features\\_fig5\\_285653348](https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features_fig5_285653348)

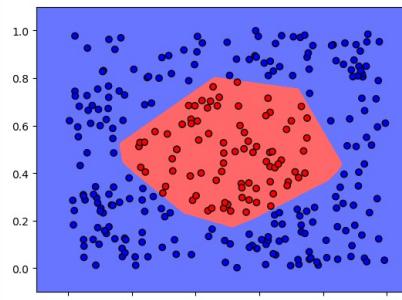
# Linear models. Classification.

Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками



[https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features\\_fig5\\_285653348](https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features_fig5_285653348)

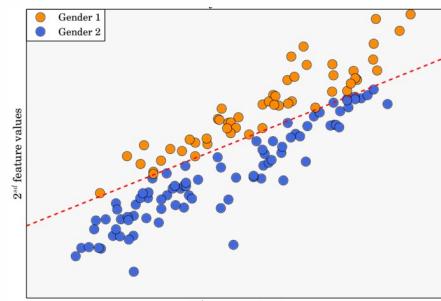


[https://cfml.se/blog/binary\\_classification/](https://cfml.se/blog/binary_classification/)

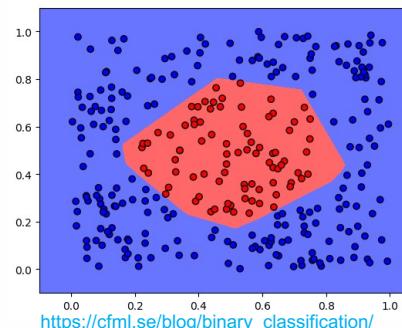
# Linear models. Classification.

Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

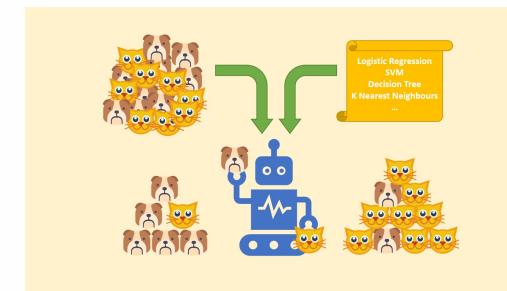
- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками



[https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features\\_fig5\\_285653348](https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features_fig5_285653348)



[https://cfml.se/blog/binary\\_classification/](https://cfml.se/blog/binary_classification/)

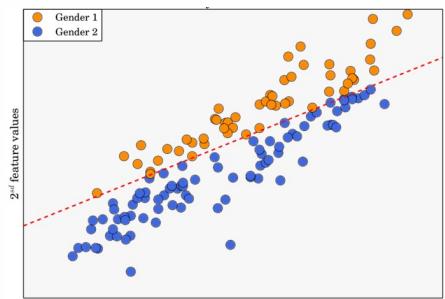


<https://towardsdatascience.com/analytics-building-blocks-binary-classification-d205890314fc>

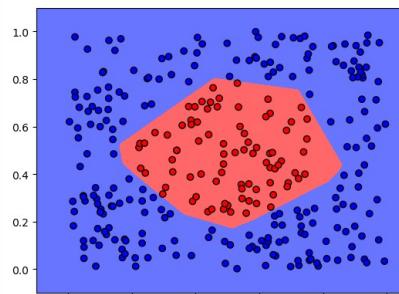
# Linear models. Classification.

Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

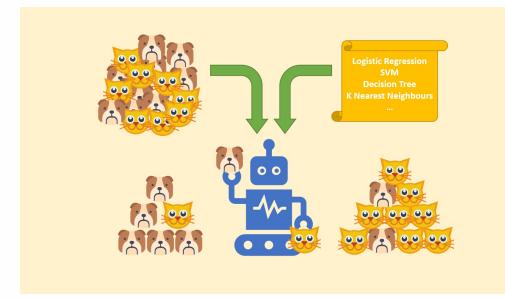
- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками



[https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features\\_fig5\\_285653348](https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features_fig5_285653348)



[https://cfml.se/blog/binary\\_classification/](https://cfml.se/blog/binary_classification/)



<https://towardsdatascience.com/analytics-building-blocks-binary-classification-d205890314fc>

Классификация может быть бинарная или мультиклассовая:

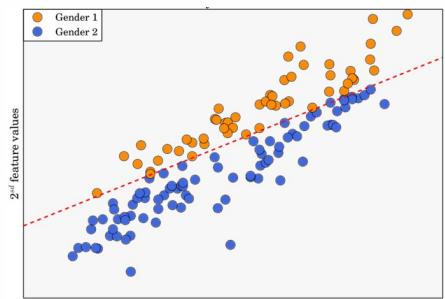
Примеры:

- Предсказание дефолта заемщика
- Предсказание направления движения акции
- Таргетирование маркетинговых коммуникаций
- К кому из 4х операторов подключится человек

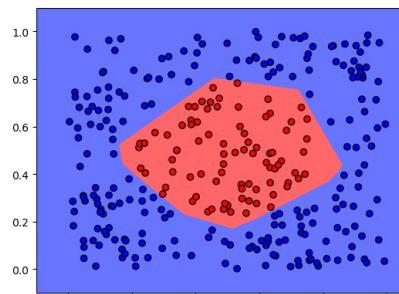
# Linear models. Classification.

Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

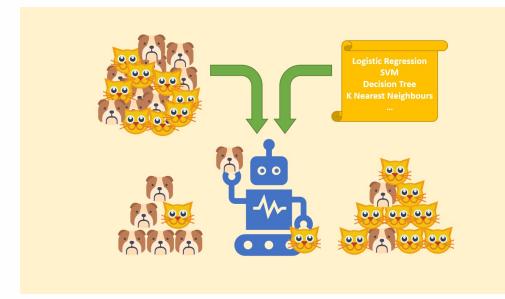
- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками



[https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features\\_fig5\\_285653348](https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features_fig5_285653348)



[https://cfml.se/blog/binary\\_classification/](https://cfml.se/blog/binary_classification/)



<https://towardsdatascience.com/analytics-building-blocks-binary-classification-d205890314fc>

Классификация может быть бинарная или мультиклассовая:

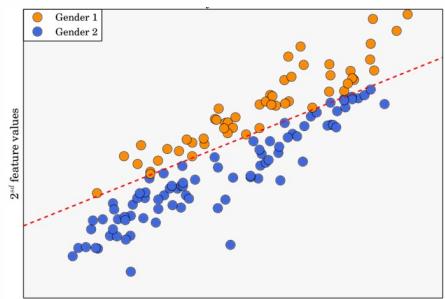
Примеры:

- Предсказание дефолта заемщика
- Предсказание направления движения акции
- Таргетирование маркетинговых коммуникаций
- К кому из 4х операторов подключится человек

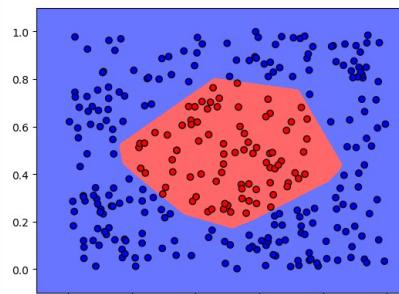
# Linear models. Classification.

Задача, которую мы решаем в проблеме классификации может также быть разбита на два типа:

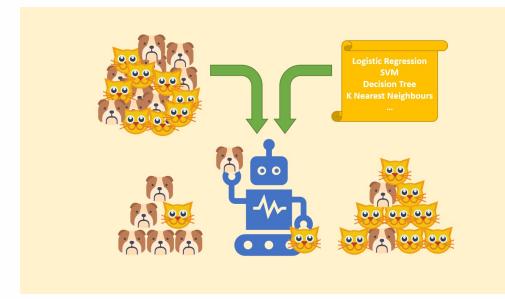
- Объяснить почему тот или иной объект принадлежит именно этому классу, а не другому
- Спрогнозировать – какому классу будет принадлежать объект с определенными характеристиками



[https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features\\_fig5\\_285653348](https://www.researchgate.net/figure/This-illustration-present-a-binary-classification-that-is-performed-on-two-features_fig5_285653348)



[https://cfml.se/blog/binary\\_classification/](https://cfml.se/blog/binary_classification/)



<https://towardsdatascience.com/analytics-building-blocks-binary-classification-d205890314fc>

Классификация может быть бинарная или мультиклассовая:

Примеры:

- Предсказание дефолта заемщика
- Предсказание направления движения акции
- Таргетирование маркетинговых коммуникаций
- К кому из 4х операторов подключится человек

# Linear models. Classification.

Решаем задачу классификации. Имеем  $y \in \{1, 2, \dots, K\}$

Как будем решать?

# Linear models. Classification.

Решаем задачу классификации. Имеем  $y \in \{1, 2, \dots, K\}$

Как будем решать?

- One vs. One

# Linear models. Classification.

Решаем задачу классификации. Имеем  $y \in \{1, 2, \dots, K\}$

Как будем решать?

- One vs. One
- One vs. All

# Linear models. Classification.

Решаем задачу классификации. Имеем  $y \in \{1, 2, \dots, K\}$

Как будем решать?

- One vs. One
- One vs. All
- Multiclass

# Linear models. Classification.

Решаем задачу классификации. Имеем  $y \in \{1, 2, \dots, K\}$

Как будем решать?

- One vs. One
- One vs. All
- Multiclass
- Линейная регрессия

# Linear models. Classification.

Решаем задачу классификации. Имеем  $y \in \{1, 2, \dots, K\}$

Как будем решать?

- One vs. One
  - One vs. All
  - Multiclass
- 
- Линейная регрессия
  - Логистическая регрессия

# Linear models. Classification.

Перейдем к другим обозначениям. Пусть линейная модель записывается:

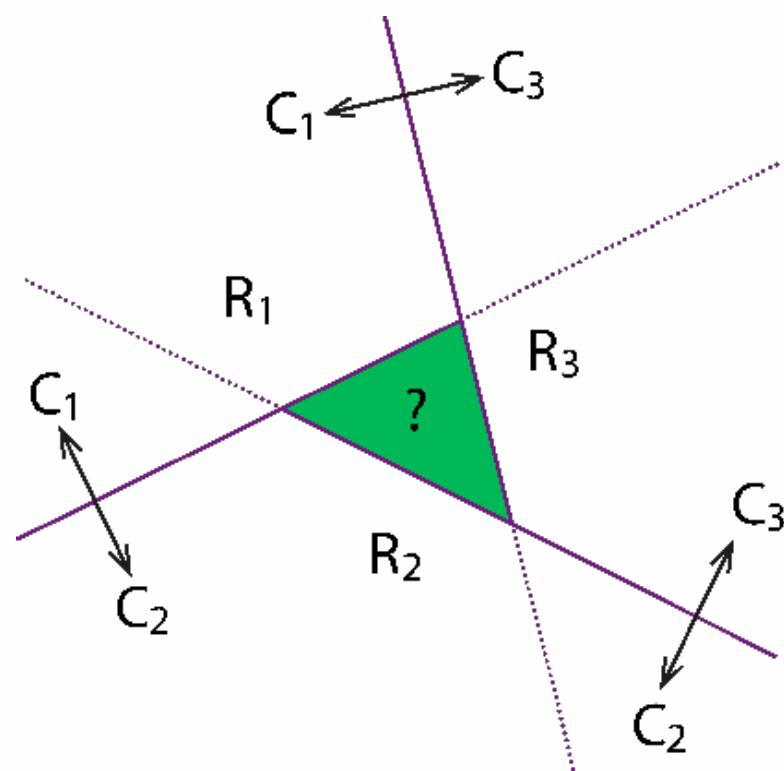
$$y(\mathbf{x}) = \mathbf{x}'\mathbf{w} + w_0$$

Пусть объект, описываемый вектором  $\mathbf{x}$  относится к классу 1, если  $y(x) \geq 0$  и к классу 2 в противном случае.

# Linear models. One vs. One.

Строим  $K(K-1)/2$  бинарных классификаторов.

Проблема:

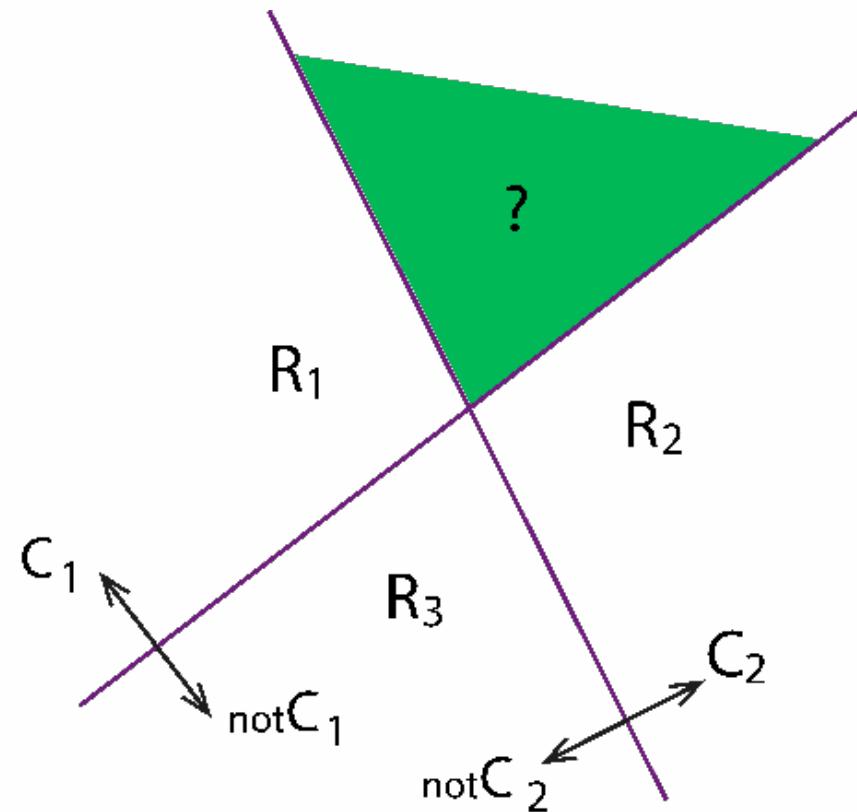


#0133

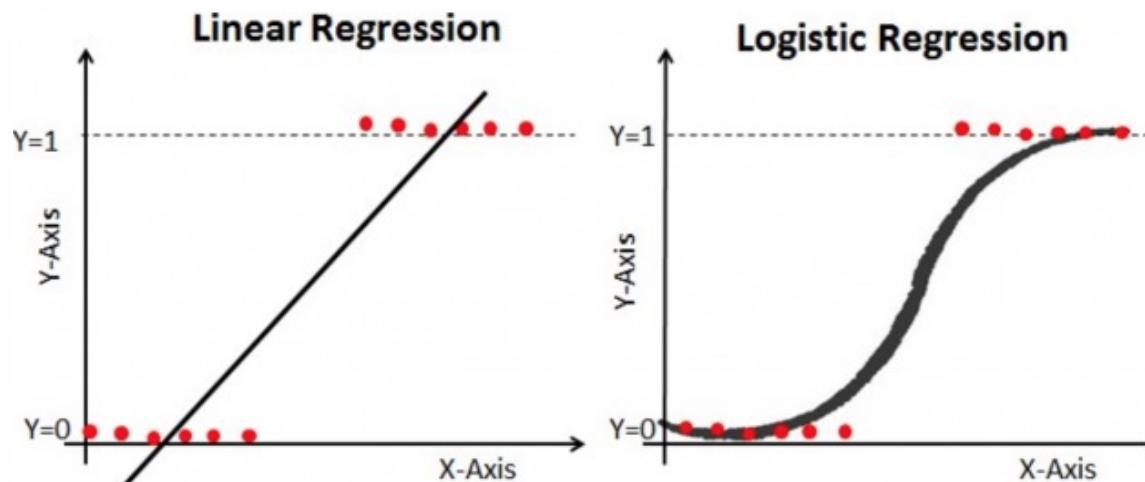
# Linear models. One vs. All.

Строим  $K-1$  бинарных классификаторов.

Проблема:



# Logistic Regression



<https://medium.com/@ODSC/logistic-regression-with-python-ede39f8573c7>

Базируется на нелинейном преобразовании.  
Позволяет учсть нормирование на единицу и неотрицательность вероятности.

---

# Logistic Regression

Это осуществляется вводом логит функции или её преобразования – сигмоиды.

---

# Logistic Regression

Это осуществляется вводом логит функции или её преобразования – сигмоиды:

$$P(y = 1|\mathbf{X})$$

# Logistic Regression

Это осуществляется вводом логит функции или её преобразования – сигмоиды:

$$P(y = 1|\mathbf{X})$$

$$\ln \frac{P(y_i = 1|\mathbf{X}_i)}{P(y_i = 0|\mathbf{X}_i)} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \epsilon_i$$

# Logistic Regression

Это осуществляется вводом логит функции или её преобразования – сигмоиды:

$$P(y = 1|\mathbf{X})$$

$$\ln \frac{P(y_i = 1|\mathbf{X}_i)}{P(y_i = 0|\mathbf{X}_i)} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \epsilon_i$$

$$z_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}$$

$$P(y_i = 1|\mathbf{X}_i) = \frac{1}{1 + \exp(-z)} + \epsilon_i = \sigma(z_i) + \epsilon_i$$

---

# Logistic Regression

Для каждого наблюдения получаем вероятность увидеть  $y=1$  при данных характеристиках.

# Logistic Regression

Для каждого наблюдения получаем вероятность увидеть  $y=1$  при данных характеристиках.

Можем записать функцию правдоподобия:

$$\mathcal{L} = \prod_{i=1}^n \left\{ P(y_i = 1 | X_i)^{y_i} (1 - P(y_i = 1 | X_i))^{1-y_i} \right\}$$

Максимизируя её по нашим параметрам бета и находя оценки мы находим оценки вероятностей исходов.

# Logistic Regression

Статистический пакет представляет результаты оценки логистической регрессии в следующем виде:

Logit Regression Results						
Dep. Variable:	target	No. Observations:	32561			
Model:	Logit	Df Residuals:	32559			
Method:	MLE	Df Model:	1			
Date:	Tue, 13 Feb 2018	Pseudo R-squ.:	0.04859			
Time:	21:24:30	Log-Likelihood:	-17101.			
converged:	True	LL-Null:	-17974.			
		LLR p-value:	0.000			
-----						
	coef	std err	z	P> z	[95.0% Conf. Int.]	
-----						
const	-2.7440	0.043	-64.211	0.000	-2.828	-2.660
age	0.0395	0.001	40.862	0.000	0.038	0.041
-----						

<https://sweetcode.io/easy-scikit-logistic-regression/>

В этой задаче классификация проводилась для события “человек зарабатывает более 50 тыс. долларов” по одной переменной – возрасту.

Давайте посмотрим как интерпретировать результаты.

# Logistic Regression

Коэффициент при age положительный, значимый на любом разумном уровне значимости и равен 0.0395.

Что происходит при увеличении возраста на 1 год?

В логистической регрессии проще всего это иллюстрировать “отношением шансов” (odds ratio).

$$\frac{\frac{P(y=1|age+1)}{P(y=0|age+1)}}{\frac{P(y=1|age)}{P(y=0|age)}} = \frac{\exp\{\alpha + \beta(age + 1)\}}{\exp\{\alpha + \beta age\}} = \exp\{\beta\}$$

То есть, при увеличении возраста на 1 год шансы получать более 50к возрастают в 1.04 раза.

Вероятность также можно получить, подставив значения коэффициентов в формулы, данные вначале.

---

# Logistic Regression

Мы можем использовать либо оценку вероятности ( $\hat{p}$ ), либо предсказанный класс.

Но мы имеем только оценку вероятности, как же получить предсказание?

---

# Logistic Regression

Мы можем использовать либо оценку вероятности ( $\hat{p}$ ), либо предсказанный класс.

Но мы имеем только оценку вероятности, как же получить предсказание?

Для этого необходимо выбрать порог (threshold), такой, что:

$$\hat{y} \in \{0, 1\}$$

$$\hat{y} = \begin{cases} 0, \hat{p} \leq threshold \\ 1, \hat{p} > threshold \end{cases}$$

# Linear models. Multiclass.

Рассмотрим multiclass logistic regression.

Предположим  $y \in \{1, 2, \dots, K\}$ .

# Linear models. Multiclass.

Рассмотрим multiclass logistic regression.

Предположим  $y \in \{1, 2, \dots, K\}$ .

Тогда, по аналогии с предыдущим запишем модель:

$$\ln \frac{P(y = 1 | \mathbf{x})}{P(y = K | \mathbf{x})} = w_{10} + w_1' \mathbf{x}$$

# Linear models. Multiclass.

Рассмотрим **multiclass logistic regression**.

Предположим  $y \in \{1, 2, \dots, K\}$ .

Тогда, по аналогии с предыдущим запишем модель:

$$\ln \frac{P(y = 1 | \mathbf{x})}{P(y = K | \mathbf{x})} = w_{10} + w'_1 \mathbf{x}$$

$$\ln \frac{P(y = 2 | \mathbf{x})}{P(y = K | \mathbf{x})} = w_{20} + w'_2 \mathbf{x}$$

...

$$\ln \frac{P(y = K - 1 | \mathbf{x})}{P(y = K | \mathbf{x})} = w_{(K-1)0} + w'_{K-1} \mathbf{x}$$

# Linear models. Multiclass.

Отсюда легко получить:

$$P(y = i|\mathbf{x}) = \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

# Linear models. Multiclass.

Отсюда легко получить:

$$P(y = i|\mathbf{x}) = \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

$$P(y = K|\mathbf{x}) = 1 - \sum_{i=1}^{K-1} \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

# Linear models. Multiclass.

Отсюда легко получить:

$$P(y = i|\mathbf{x}) = \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

$$P(y = K|\mathbf{x}) = 1 - \sum_{i=1}^{K-1} \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

$$P(y = K|\mathbf{x}) = \frac{1}{1 + \sum_{i=1}^{K-1} \exp(w_{i0} + w_i' \mathbf{x})}$$

# Linear models. Multiclass.

Отсюда легко получить:

$$P(y = i|\mathbf{x}) = \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

$$P(y = K|\mathbf{x}) = 1 - \sum_{i=1}^{K-1} \exp(w_{i0} + w_i' \mathbf{x}) P(y = K|\mathbf{x})$$

$$P(y = K|\mathbf{x}) = \frac{1}{1 + \sum_{i=1}^{K-1} \exp(w_{i0} + w_i' \mathbf{x})}$$

Далее действуем, применяя метод максимального правдоподобия и получаем оценки для параметров  $w$ .